



Bachelorthesis

Entwicklung einer kamerabasierten Detektion und Verfolgung linienförmiger Objekte am Meeresboden

Prüfling:

Name: Oliver Gruhlke (ogruhlke@tzi.de)

Matrikelnummer: 278736

Erstprüfer:

Prof. Dr. Frank Kirchner (Frank.Kirchner@dfki.de)

Zweitprüfer:

Dr.-Ing. Dipl.-Inform. Thomas Röfer (Thomas.Roefer@dfki.de)

Betreuer:

Christopher Gaudig (Christopher.Gaudig@dfki.de)

Max Abildgaard (Max.Abildgaard@atlas-elektronik.com)

Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Arbeit selbstständig und nur unter Zuhilfenahme der angegebenen Quellen und Hilfsmittel verfasst zu haben. Die aus fremden Quellen direkt oder indirekt übernommenen Stellen sind als solche kenntlich gemacht. Ich bestätige außerdem, dass die vorliegende Arbeit noch nicht im Rahmen eines anderen Prüfungsverfahrens eingereicht wurde.

Ort, Datum

Oliver Gruhlke

1. Einleitung	1
1.1. Motivation	1
1.2. Grundidee	1
1.3. Aufbau der Arbeit	2
2. Grundlagen	3
2.1. Simulationsumgebung	3
2.2. AUV-Simulation	3
2.3. Koordinatensysteme	4
2.3.1. Bild und Kamera	4
2.3.2. Body	5
2.3.3. MATLAB und VRML (World)	6
2.4. Eingesetzte Software	7
3. State of the Art	8
3.1. Objekterkennung	8
3.1.1. Linienerkennung	8
3.1.2. Andere Ansätze	11
3.2. Schätzverfahren	14
3.2.1. Kalman-Filter	15
3.2.2. Regressionsverfahren	16
4. Lösungsansatz	18
4.1. Simulationserweiterung	19
4.1.1. Steuerung	19
4.1.2. Kamerabilder	20
4.2. Transformation	22
4.2.1. Bild zu Kamera	23
4.2.2. Kamera zu Body	23
4.2.3. Body zu Welt	24
4.2.4. Welt zu VRML	25
4.3. Objekterkennung	26
4.3.1. Binärbild mit Template	26
4.3.2. RANSAC auf Binärbild	29
4.4. Schätzverfahren	32

5. Tests und Evaluation	35
5.1. Tests Objekterkennung	36
5.2. Testläufe	42
5.2.1. Gerader Verlauf	42
5.2.2. Kurve	44
5.2.3. Kreisbahn	49
5.2.4. Schlechte Sichtbedingungen	52
5.3. Parametrisierung	54
5.3.1. Einpendeln	54
5.4. Systematischer Fehler	56
5.5. Laufzeittests	57
6. Fazit & Ausblick	58
6.1. Fazit	58
6.2. Ausblick	59
6.2.1. Parametrisierung	59
6.2.2. Regressionsverfahren	59
6.2.3. Integration in Realsystem	60
A. Literaturverzeichnis	61
B. Abbildungsverzeichnis	63
C. Gleichungsverzeichnis	66
D. Listingverzeichnis	67
E. Anhang	68
E.1. Objekterkennung weitere Tests	68

1. Einleitung

Diese Bachelorarbeit behandelt die Entwicklung einer Detektion und Verfolgung von Objekten am Meeresboden. Es wird eine Komponente entwickelt, die einem AUV eben dies ermöglicht. Diese Komponente beinhaltet die Erkennung der Objekte, die Schätzung des Objektverlaufs und die Steuerung des AUVs anhand von Wegpunkten.

1.1. Motivation

Die Motivation für die Arbeit entspringt der Idee, Kameradaten in einem Robotersystem dezentral zu verarbeiten. So kann die Verarbeitung der Bilddaten auf einem eigenen Prozessor innerhalb der Kamerakomponente umgesetzt werden. Somit würden dem System keine rohen Daten, sondern verwertbare Informationen geliefert.

Ein mögliches Beispiel hierfür ist ein Missionsszenario, in dem ein AUV einem Objekt am Meeresboden autonom folgen soll. So können Strukturen (Kabel, Pipelines etc.) von einem AUV untersucht werden, ohne dass ein Pilot das Fahrzeug steuern und überwachen muss.

Die Kamerakomponente kann hierbei eine Lageposition des Objektes liefern, anstatt eines Bildes, das zentral verarbeitet werden müsste. Die Software für dieses Szenario wird in dieser Arbeit entwickelt.

1.2. Grundidee

Die zu entwickelnde Komponente soll dem AUV eine verlässliche Information über die Objektlage liefern. Hierfür gilt es zwei Hauptprobleme zu lösen.

Zum ersten ist dies die Erkennung der Objekte im Bild. In dieser Arbeit beschränke ich mich auf linienförmige Objekte. Die Bilderkennung soll Position und Ausrichtung des Objektes relativ zum AUV bestimmen können. Das zweite Problem ist die Bestimmung relevanter Daten, wenn die Bilderkennung kein Objekt finden kann, sei es durch zeitweises Versagen der Algorithmik, nicht verwertbare Rohdaten oder durch Unsichtbarkeit der Objekte, wenn diese zum Beispiel von Sand überdeckt sind. In diesem Fall soll ein Schätzverfahren auf Basis der vorherigen Positionsdaten auch weiterhin die ungefähre Objektlage liefern.

Als Hilfe für die Algorithmen soll es möglich sein a-priori Wissen über die Objekte, wie zum Beispiel den Durchmesser des Objektes angeben zu können.

1.3. Aufbau der Arbeit

Zunächst wird grundlegend die Simulationsumgebung und das AUV beschreiben. Danach werden verschiedene Herangehensweisen ähnlicher Arbeiten vorgestellt und die Eignung für das zu lösende Problem diskutiert. Im dritten Teil wird dann die gewählte und umgesetzte Lösung beschrieben. Zum Schluss folgen dann Ausführungen über die durchgeführten Tests und ein Fazit, sowie ein Ausblick auf weitere Arbeiten.

2. Grundlagen

2.1. Simulationsumgebung

Die Simulationsumgebung wurde von der ATLAS ELEKTRONIK GmbH entwickelt und wird für diese Arbeit zur Verfügung gestellt [Abb. 1]. In der Simulation wird die Fahrzeugsensorik und Aktuatorik simuliert (siehe Kapitel 2.2). Außerdem wird noch eine grundlegende Wasserbewegung erzeugt, die durch Parametrisierung verändert werden kann.

Die Umgebung an sich besteht aus *wrl*-Dateien, in denen die Welt mit *VRML* beschrieben wird. Diese einzelnen Dateien werden in der *main.wrl* zusammengefügt. Bereits vorhanden sind *wrl*-Dateien für das AUV, in denen die Realvorlage maßstabsgetreu nachgebildet wird, sowie ein Generator zum Erstellen zufallsgenerierter Meeresböden in *wrl*. Die Objekte, die in der Arbeit verfolgt werden sollen, wurden in *VRML* modelliert und dann als Unterknoten in der *main.wrl* hinzugefügt.

Die Simulation basiert auf der MATLAB Simulink 3D Animation Toolbox, somit stehen auch weitere MATLAB -Toolboxen zur Verfügung.

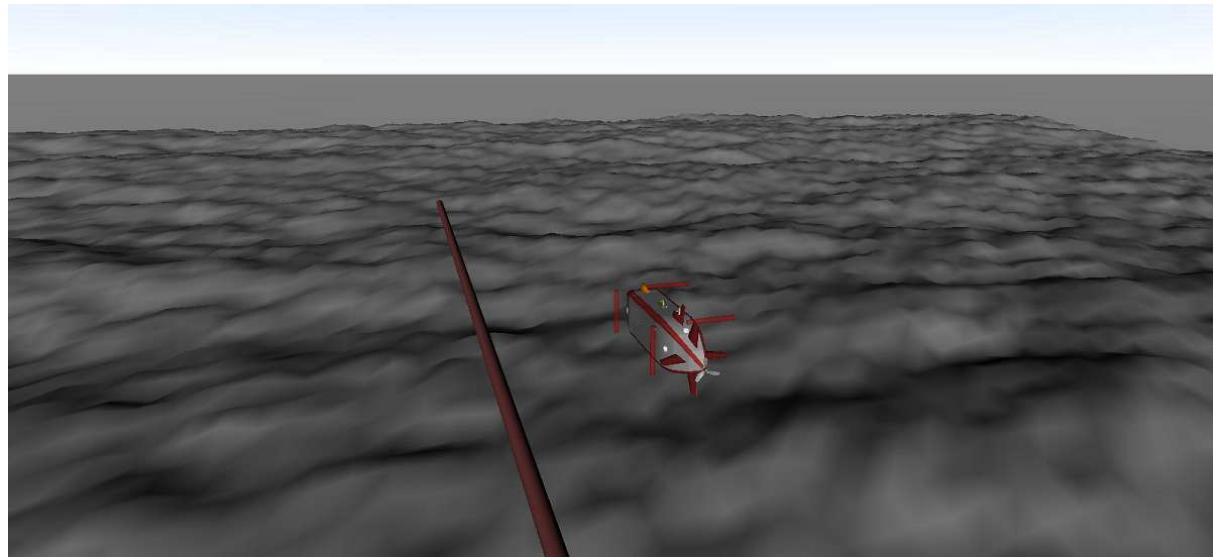


Abbildung 1: Screenshot der Simulationsumgebung mit dem AUV, einem Testobjekt und dem generierten Meeresboden

2.2. AUV-Simulation

Das simulierte AUV wurde von der ATLAS ELEKTRONIK GmbH auf Grundlage eines der eigenen AUVs entwickelt. Zu dieser Simulation gehören die bereits erwähnten *wrl* Dateien sowie eine Simulation der Fahrzeugaktuatorik und -sensorik in MATLAB Simulink. Es werden die für die Steuerung benötigte Schnittstelle in Form von Wegpunkten und

umrechnun
lat
lon zu
meter

eine Schnittstelle für die innere Sensorik des AUVs bereitgestellt. Die für diese Arbeit wichtigen Informationen aus der inneren Sensorik bestehen aus der Pose des AUVs in der Welt bestehend aus geografischen Koordinaten, der Höhe über dem Meeresboden und den Roll-, Pitch- und Yaw-Werten.

Für die Steuerung wird ein `lane follower controller` verwendet, bei dem eine Linie zwischen einem neuen und altem Wegpunkt gebildet und diese dann verfolgt wird. Für die Höhenkontrolle werden zwei Steuerungsmodi zur Verfügung gestellt. Zum einen die Fahrt auf Tiefe unter der Wasseroberfläche oder Höhe über Meeresboden. Für diese Arbeit wird die Fahrt auf Höhe über dem Meeresboden gewählt, da die Transformation von Pixelkoordinaten in Kamerakoordinaten am zuverlässigsten in dem Abstand zum Objekt funktioniert, in dem auch die Kamerakalibrierung durchgeführt wurde. Änderungen der Höhe können zu leichten Fehlern in der Positionsbestimmung führen. Jedoch sind diese Fehler bei realistischen Höhenunterschieden von einigen Metern nicht ausschlaggebend für die Ergebnisse der Arbeit.

Am Bug des AUVs befindet sich eine Kamera, die zentral nach unten ausgerichtet ist. Das Sichtfeld beträgt dabei 45° bei einer Auflösung von 640x480 Pixeln.

2.3. Koordinatensysteme

Im Folgenden werde ich die Koordinatensysteme beschreiben, in denen Koordinaten angegeben werden. Ich gehe hierbei von einer Tangentialebene an der WGS84-Kugel verschoben auf den Meeresboden aus, da nur hinreichend kleinen Operationsgebiete des AUVs link betrachtet werden, sodass die Erdkrümmung keine Auswirkung hat.

2.3.1. Bild und Kamera

Das Bildkoordinatensystem [Abb. 2] beschreibt die Anordnung der Pixel im Bild als 2D-Koordinaten. Der Ursprung ist immer die linke obere Bildecke. Ich gehe davon aus, dass das Bildkoordinatensystem immer auf der Meeresbodenebene liegt. Diese Annahme ist wichtig für die Transformationen [Kapitel 4.2].

schönere
grafik
evtl
selber
machen

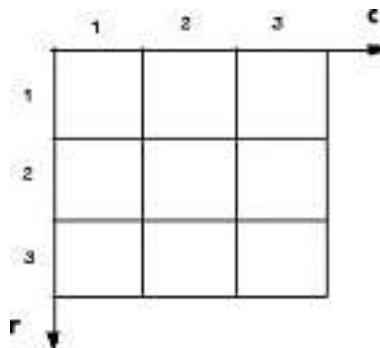


Abbildung 2: Anordnung der 2D-Pixelkoordinaten. Ursprung liegt in der linken oberen Bildecke. Die X-Achse bildet die Bildspalten und die Y-Achse die Bildzeilen ab.

Das Kamerakoordinatensystem [Abb. 3] beschreibt das dreidimensionale Koordinatensystem mit Ursprung im Mittelpunkt der Kameralinse. Die Kamera befindet sich 25 cm unter und 1,3 m vor dem Fahrzeugmittelpunkt.

bessere
qualität

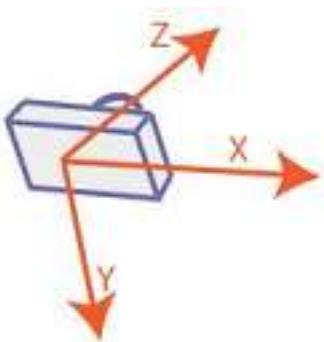


Abbildung 3: Das Kamerakoordinatensystem. Ursprung des Systems liegt im Mittelpunkt der Kameralinse. Die X-Achse bildet die Bildspalten und die Y-Achse die Bildzeilen im Raum ab. Die Z-Achse zeigt in Blickrichtung der Kamera.

2.3.2. Body

Das Body-Koordinatensystem beschreibt das Koordinatensystem relativ zum AUV-Mittelpunkt [Abb. 4]. Der Ursprung wird hierbei durch den Massenschwerpunkt des AUVs bestimmt. Das Koordinatensystem entspricht dem klassischen nautischen Koordinatensystem, dem North-East-Down Koordinatensystem (vgl. Kapitel 2 in *Unmanned rotorcraft systems* [5])

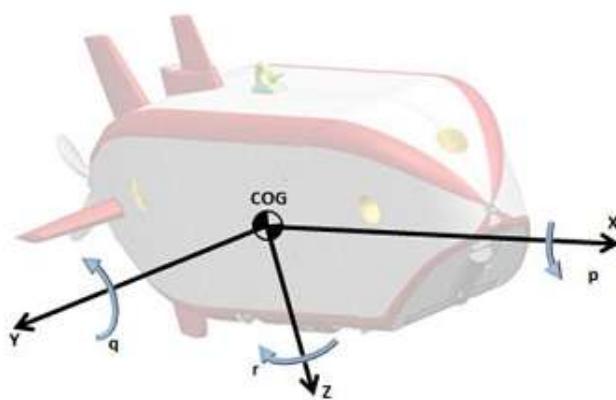


Abbildung 4: Das Body-Koordinatensystem mit Massenschwerpunkt (*cog*) des AUVs. Die X-Achse zeigt frontal voraus, die Y-Achse Richtung Steuerbord und die Z-Achse zeigt nach unten. p r und q beschreiben die Neigungswinkel und Rotationsrichtung an den jeweiligen Achsen (vgl. Abb. 5)

Die Neigungswinkel (Roll-Pitch-Yaw) werden wie in [Abb. 5] im Body Koordinatensystem angegeben.

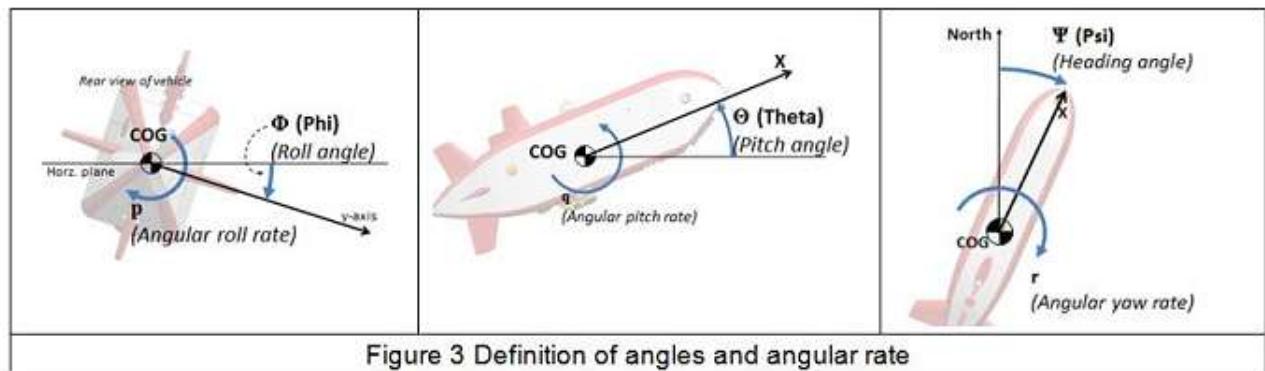


Abbildung 5: Die Neigungswinkel am AUV. Phi beschreibt den Roll Winkel um den Massenschwerpunkt (*cog*) und p die dazugehörige *roll rate*, Theta beschreibt den Pitch Winkel um den Massenschwerpunkt (*cog*) und q die dazugehörige *roll rate* und Psi beschreibt die Ausrichtung des AUVs im Bezug zur Nordrichtung.

2.3.3. MATLAB und VRML (World)

Abbildung 6 zeigt die Koordinatensysteme der MATLAB -Grafikbibliothek und der *VRML* -Bibliothek. Zum Berechnen der Wegpunkte für die Steuerung des AUVs muss eine Pose in das *VRML* -Koordinatensystem transformiert werden. Der Ursprung beider Systeme liegt im Mittelpunkt der Simulationsumgebung.

figure
3 weg
machen

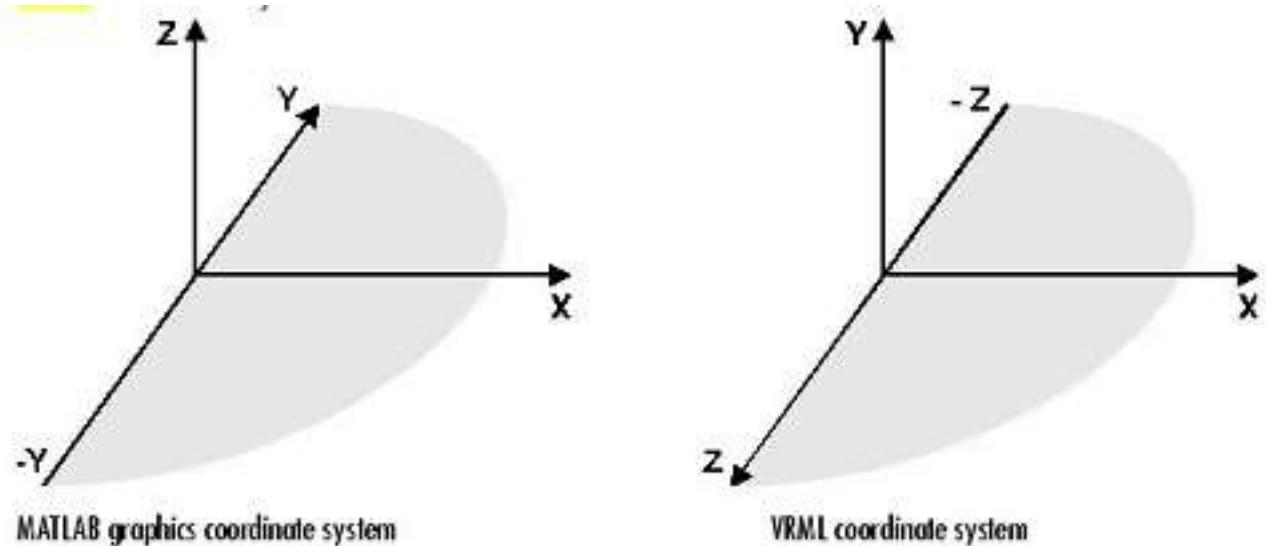


Abbildung 6: MATLAB und VRML Koordinatensystem. Der Ursprung beider Systeme definieren den Mittelpunkt der Simulationsumgebung. Die X-Achsen zeigen in beiden Fällen Richtung Norden. Im VRML -System zeigt die Z-Achse Richtung Ost, im MATLAB -System zeigt dementsprechend die negative Y-Achse Richtung Ost. In beiden Systemen liegt die Grundfläche auf dem Meeresboden. Somit zeigt die Z- bzw. Y-Achse vom Meeresboden aufwärts.

schöner
evtl
mit tik

2.4. Eingesetzte Software

Neben den bereits erwähnten MATLAB -Bibliotheken *Simulink*, *Graphics* und *3D Animation* werden in dieser Arbeit noch weitere Bibliotheken verwendet.

Grundlegende geometrische Berechnungen, zum Beispiel Transformationen in 2D und 3D oder auch Distanzberechnungen von Punkten werden mithilfe der freien Bibliotheken *geom2d*¹ und *geom3d*² durchgeführt.

Das Schätzverfahren nutzt die *Optimization-Toolbox*³, die Lösungen für verschiedene Minimierungs-, Maximierungs- und Optimierungsprobleme liefert.

Für die Kamerakalibrierung wurde die *Computer Vision System Toolbox* genutzt. Die Toolbox bietet die einfach zu bedienende *Camera Calibration App* mit der die intrinsischen Parameter bestimmt werden können. Hilfestellung lieferte hierbei das dazugehörige Tutorial⁴.

¹ <https://de.mathworks.com/matlabcentral/fileexchange/7844-geom2d>

² <https://de.mathworks.com/matlabcentral/fileexchange/24484-geom3d>

³ <https://de.mathworks.com/products/optimization.html>

⁴ <https://de.mathworks.com/help/vision/ug/single-camera-calibrator-app.html>

3. State of the Art

In diesem Kapitel werden verwandte Arbeiten zum Thema dieser Arbeit vorgestellt. Außerdem wird erläutert, inwiefern die vorgestellten Arbeiten sich zum Lösen der gestellten Aufgabe eignen.

Ich unterteile meine Arbeit hierbei in die Oberpunkte *Objekterkennung*, zum Detektieren der Objekte und Bestimmen der Lage, und das *Schätzverfahren*, zur Bestimmung und Vorhersage des Objektverlaufs.

3.1. Objekterkennung

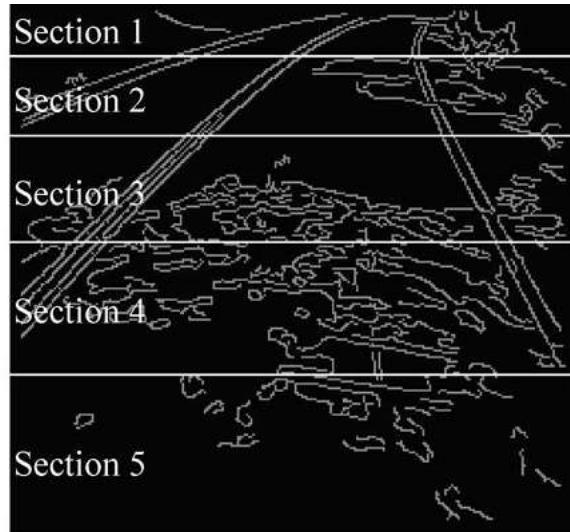
Bei der Objekterkennung unterscheide ich grob zwischen Ansätzen, die Objekte aufgrund von Linien und deren Beziehungen detektieren und solchen, die andere Objekteigenschaften nutzen.

3.1.1. Linienerkennung

Linienförmige Objekte heben sich unter anderem durch zwei annähernd parallel verlaufende Kanten vom Hintergrund ab. Ein verwandtes Problem hierzu ist die Detektion eines Straßenverlaufs, der sich ebenso durch zwei fast parallele Linien (den Fahrbahnmarkierungen) auszeichnet [Abb. 7].



(a)



(b)

Abbildung 7: Ein typischer Straßenverlauf mit entsprechendem Kantenbild und dem Ansatz der vertikalen Unterteilung in mehrere Segmente aus Lane detection and tracking using B-Snake[18].

Viele Arbeiten zum Tracking von Fahrbahnmarkierungen basieren auf der Kantenextrak-

3. State of the Art

tion ([17],[2], [12],[18]). Aus dem Kantenbild werden dann die Charakteristiken der Straße extrahiert. Hierfür wird oft versucht, mithilfe von LCFs (lane-curve-function) die Markierungen zu finden. Dies eignet sich besonders gut, um den typischen Straßenverlauf in Form von leichten Kurven zu erkennen. Eine LCF stellt ein Modell des gekrümmten Straßenverlaufs dar, das sich durch Parameter bestimmen lässt. Hierbei unterscheidet sich die LCF in zwei Breiche. Zum einen einen geraden Beginn, gefolgt von einem gekrümmten Bereich.

Jong Woung Park et al.[12] untersuchen Straßenbilder mithilfe von LCFs und einem Krümmungsindex, der die Richtung und Stärke der Krümmung beeinflusst. Bestimmt wird dabei, ob es sich im Bild um eine gerade, nach links oder nach rechts gebogene Straße handelt.

Die Methode setzt dabei voraus, dass die geraden Anfänge der Straßenmarkierungen nah an der Kamera sowie der *vanishing point* bereits erkannt wurden. Der *vanishing point* ist der Punkt, an dem sich parallele Linien projiziert auf die Bildebene schneiden (vgl. Abb. 10). Aus diesem Wissen werden zunächst die von der Krümmung unabhängigen Parameter der LCF berechnet. Der Bereich weiter entfernt von der Kamera bestimmt dann die Krümmung der gesuchten LCF. Hierfür wird für die verschiedenen Krümmungen eine *region of interest* (ROI) um die LCF definiert. Innerhalb der ROI wird dann mithilfe von Kantenerkennung evaluiert, welcher Krümmungsgrad am ehesten den Fahrbahnverlauf abbildet. Dieses Verfahren ist in Abbildung 8 zu sehen, in dem die ROI der Linkskurve das beste Ergebnis liefert.

[glossar?](#)

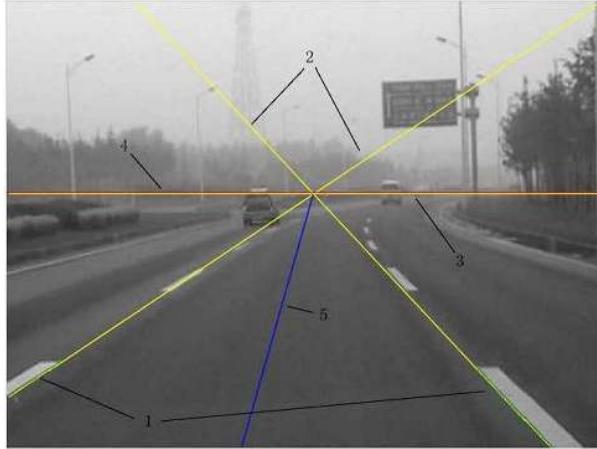


Abbildung 8: Detektion des Straßenverlaufs mithilfe von LCF und ROI. Die schwarz umrahmte Fläche bestimmt die ROI. Die Kurven der drei Bilder werden durch verschiedene Krümmungindizes der LCF erzeugt. Die von der Krümmung unabhängigen Parameter der LCF sind in allen Bildern gleich.

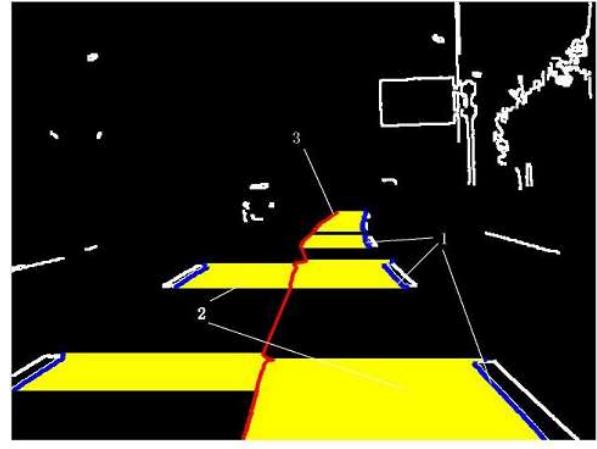
Alternativ können auch gerade Linien im Kantenbild gesucht werden. In A Real-time Lane Detection Algorithm Based on a Hyperbola-Pair Model [6] suchen Chen et al. mithilfe des RANSAC -Algorithmus auf einem Kantenbild zwei gerade Linien. Auf Grundlage der gefundenen Linien wird dann die Mitte der Straße und in weiteren Schritten dann

3. State of the Art

auch der Straßenverlauf bestimmt [Abb. 9].



(a) Ursprungsbild mit Linien- und Horizontmarkierungen



(b) Kantenbild mit Bereichen zwischen zwei Linien und Mitte der Straße

Abbildung 9: Erkennungsprozess aus *A Real-time Lane Detection Algorithm Based on a Hyperbola-Pair Model*. Im rechten Bild ist in rot die detektierte Straßenmitte gekennzeichnet.

Einen ähnlichen Ansatz verfolgen auch Wang et al. für ihre Detektion in *Lane detection and tracking using B-Snake[18]*. Besonders hierbei ist, dass das Eingabebild vertikal in fünf Segmente eingeteilt wird (siehe Ab. 7). In jedem Segment werden mithilfe der *Hough Transformation* Linien erkannt und wie bei Chen die Mitte der Straße bestimmt. Außerdem wird für jedes Segment auch der *vanishing point vp* bestimmt. Der *vanishing point* eines Segmentes bestimmt die Richtung der detektierten Straße (siehe Abb. 10). Die Arbeit bietet eine Möglichkeit innerhalb eines Bildes eine Kurve zu detektieren, obwohl nur gerade Linien gesucht wurden.

3. State of the Art

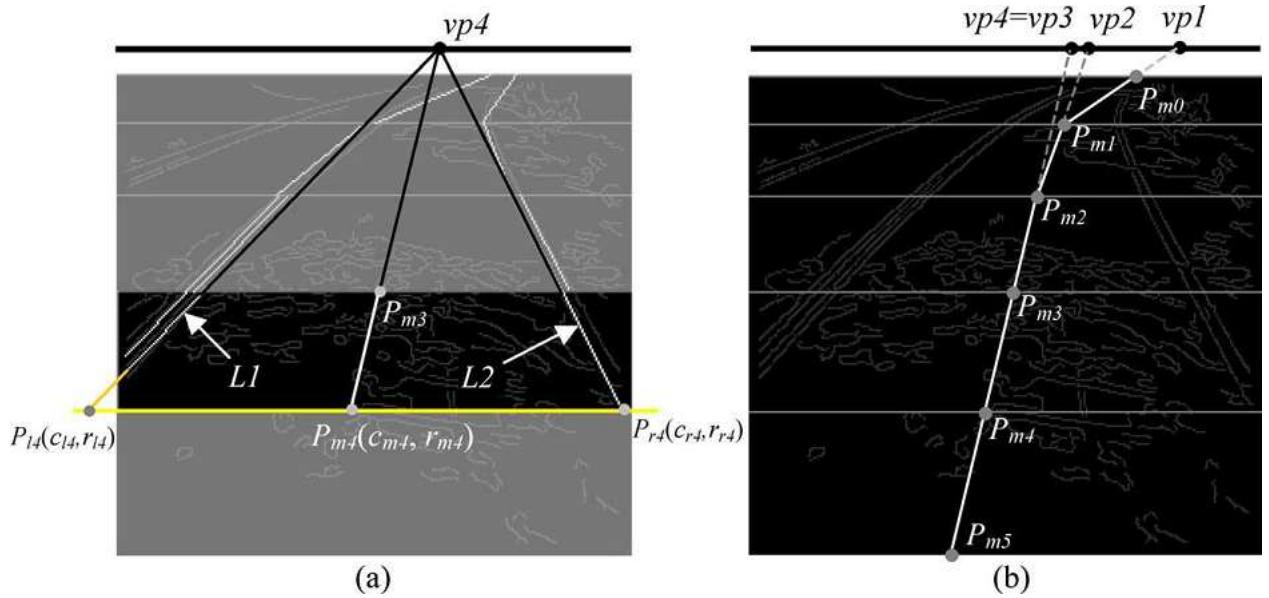


Abbildung 10: Ergebnis der Straßenverlaufsdetektion mithilfe von *Hough Transformation* nach Wang et al.. Links werden die erkannten Straßenmarkierungen der Segmente angedeutet und der *vanishing point* des vierten Segmentes. Rechts ist die final detektierte Mittellinie der Straße über alle Segmente.

Aus den von mir betrachteten Arbeiten geht hervor, dass mithilfe von LCFs kurvige Straßenverläufe gut erkannt werden können. Da Kameras in den betrachteten Arbeiten jedoch nach vorne ausgerichtet sind, um den Straßenverlauf möglichst weit zu erkennen, unterscheidet sich dieser Ansatz in einem wesentlichen Punkt vom Unterwasserszenario. In den meisten Einsatzgebieten würde eine nach vorn ausgerichtete Kamera keine Objekte am Meeresboden sehen können. Der Höhenunterschied von der Kamera zum Boden wäre zu groß um Objekte nah am Fahrzeug zu sehen und in der Entfernung sind oftmals, bedingt durch schlechte Sichtverhältnisse, keine Objekte erkennbar. Aus diesen Gründen sollte die Kamera gerade nach unten oder leicht nach vorne geneigt ausgerichtet sein. Aus dieser Ausrichtung resultiert jedoch, dass der betrachtete Bereich weitaus kleiner ist und die meisten Objekte nur eine sehr leichte Krümmung im Bild aufweisen. Hier reicht eine Linienerkennung aus.

3.1.2. Andere Ansätze

Im CSurvey-Projekt [1] beleuchten Albize et al. eine Pipeline mit einem Linienlaser und erkennen die Linie im Kamerabild über den Helligkeitswert. Für die Detektion wird für jede Bildzeile ein Helligkeitsmaximum gesucht. Hierfür wird ein Template, das den typischen Helligkeitsunterschied der beleuchteten Pipeline zum Hintergrund abbildet, auf die Zeile angewandt [Abb. 11].

Diese Detektion wurde vor allem in verschiedenen Entfernungen zum Boden und verschiedenen Trübungsgraden des Wassers getestet. Ein Ergebnis der Arbeit ist, dass mit dem

3. State of the Art

Template auch bei schlechter Sicht die Pipeline noch erkennbar ist. Jedoch wird ab einem bestimmten Trübungsgrad das gesamte Bild zu hell für eine Erkennung, da die Reflexion des Laserlichts im trüben Wasser viel zu groß ist.

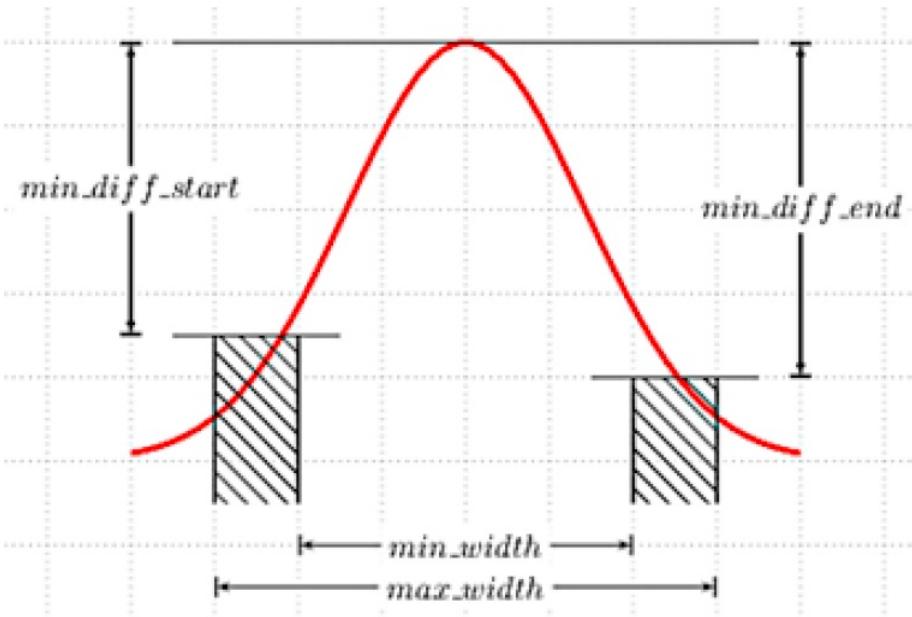
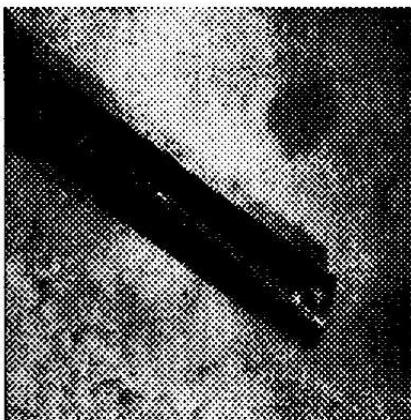


Abbildung 11: Template zur Detektion auf Helligkeitsdaten aus *CSurvey*.

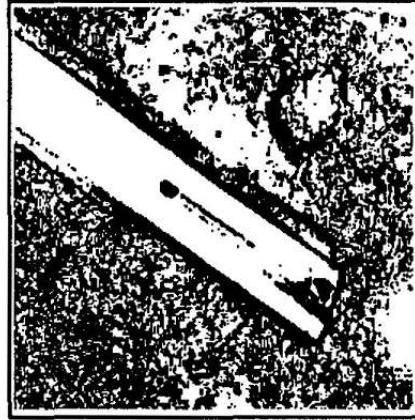
Im **Avalon-Projekt** [7] wird eine Pipeline mit einem Farbfilter im HSV-Farbraum detektiert. Dieser Filter erzeugt zuerst ein Binärbild. Auf diesem Binärbild wird dann mit einem Canny Edge Detector ein Kantenbild generiert. Im Kantenbild wird mithilfe der Hough-Transformation nach Linien gesucht.

In **Simple vision tracking of pipelines for an autonomous underwater vehicle**[9] wird ähnlich wie bei den Linienerkennungsansätzen eine Kantenerkennung durchgeführt. Im Kantenbild werden dann mithilfe von Segmentierung Regionen definiert. Auf diese Regionen werden dann umschließende Rechtecke gelegt. Aus diesen Rechtecken lässt sich dann die gesuchte Pipeline bestimmen.

3. State of the Art



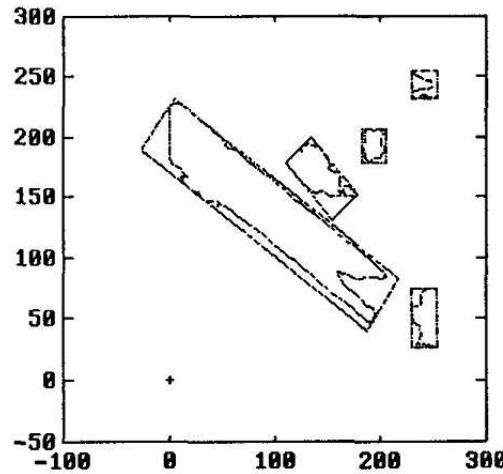
(a) Originalbild nach Kontrastverstärkung



(b) Kantenbild durch Sobel-Filter



(c) Segmentiertes Bild



(d) Erkannte Rechtecke

Abbildung 12: Einzelschritte der Erkennung aus *Simple vision tracking of pipelines for an autonomous underwater vehicle*. Die Pipeline wird hierbei durch das Untersuchen des Kantenbildes auf rechteckige Strukturen detektiert.

Foresti et al. detektieren in *A Vision Based System for Object Detection in Underwater Images* Unterwasserpipelines mithilfe eines neuronalen Netzes. In Abbildung 13 ist zu sehen, dass die Pipelines sehr gut erkannt wurden. Selbst bei vom Sand verdeckte Pipeline (c und d) werden die Kanten der Pipelines noch richtig bestimmt.

3. State of the Art

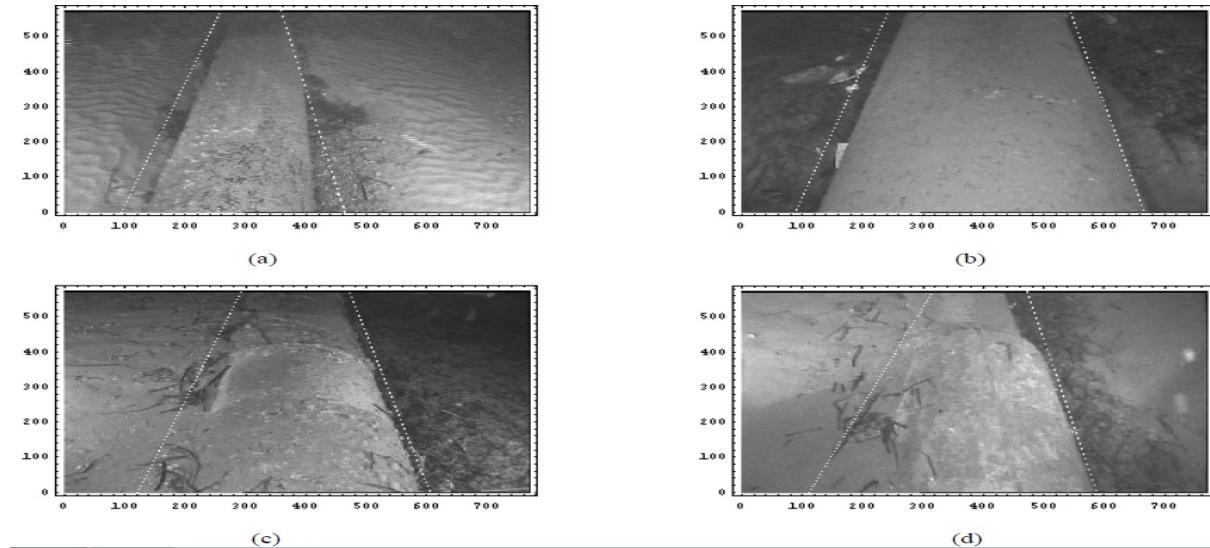


Abbildung 13: Pipelines erkannt mithilfe eines neuronalen Netzwerks

Trotz dieser guten Ergebnisse habe ich mich gegen ein neuronales Netz entschieden. Zum einen gab es zu Beginn der Arbeit keine geeigneten Trainingsbilder aus der Simulationsumgebung, um das Netz zu trainieren. Außerdem ist ein neuronales Netz stets als *black box* zu betrachten und die Detektion ist nicht eindeutig nachvollziehbar. Neben diesen Faktoren ist auch der Berechnungsaufwand für ein neuronales Netz höher einzuschätzen, als bei anderen Ansätzen.

Aus diesen Gründen habe ich mich für einen leichter zu implementierenden, klassischeren Ansatz der Bildverarbeitung entschieden.

Die auf Linienerkennung basierenden Ansätze eignen sich sehr gut, solange klare Kanten im Bild erkennbar sind. Im Unterwasserszenario setzt dies gute Sicht- und Lichtverhältnisse voraus. Außerdem würden vom Meeresboden verdeckte Objekte keine oder sehr kurvige Kanten ergeben, in denen die vorgestellten Ansätze keine Ergebnisse liefern würde. Beide Voraussetzungen sind im Unterwasserbereich nicht erfüllbar, weswegen in dieser Arbeit ein anderer Ansatz gewählt wurde.

Sehr gut eignet sich ein Helligkeitsbasierter Ansatz. Wie im *CSurvey*-Projekt[1] gezeigt, kann ein solcher Ansatz selbst unter schlechten Sichtbedingungen noch gute Ergebnisse liefern. Es ist zu erwarten, dass auch in der verwendeten Simulationsumgebung gute Resultate erzielt werden können.

3.2. Schätzverfahren

Wie in der Einleitung beschrieben muss ein Schätzverfahren entwickelt werden, um dem Objektverlauf optimal folgen zu können. Das Verfahren muss auf der Ausgabe der Objekterkennung aufsetzen.

3. State of the Art

3.2.1. Kalman-Filter

Ein Kalman Filter ist eine Möglichkeit, um verrauschte Messwerte zu verbessern und auch ausbleibende Messungen auszugleichen. Der Kalman Filter basiert auf einem linearen State wie zum Beispiel der Pose und Posenänderung eines Roboters. In jedem Zeitschritt des Filters wird aufgrund des vorherigen Zustands und dem Weltmodell ein Folgezustand berechnet und dieser dann mit den aktuellen Messwerten verglichen.(vgl. *Optimal State Estimation, Chapter 5*[15]). In *Real-Time Visual Tracking of a Moving Object Using Pan and Tilt Platform: A Kalman Filter Approach*[16] nutzen Bahare Tor-kaman und Mohammad Farrokhi einen Kalman Filter, um die Bewegung eines Objektes, das mit einer Kamera detektiert wird, zu verfolgen (siehe Abb. 14). Der State des Kalman Filters ist dabei die x - und y -Position des Objektes in der Ebene, sowie dessen aktuelle Positionsänderung. Der Zustandsübergang wird durch die Objektbewegung durchgeführt. Das Update der Messung besteht aus der erkannten Position der Objekterkennung. In der Arbeit ist sehr gut zu sehen, wie der Kalman-Filter den Fehler der Objekterkennung nahezu halbiert.

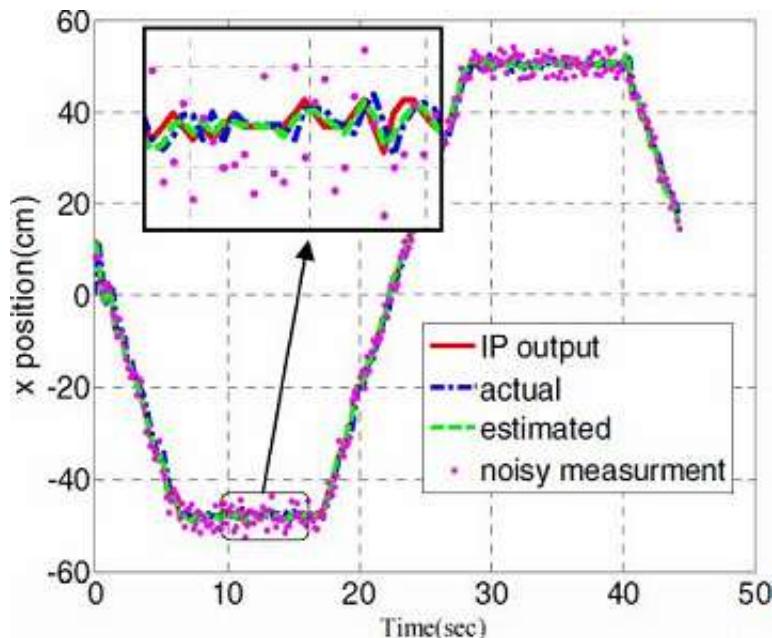


Abbildung 14: Eine Objektbewegung wird mit einem Kalman-Filter verfolgt

Der Kalman Filter eignet sich jedoch nicht gut für das gestellte Szenario. Um den Messfehler der Objekterkennung auszugleichen, müsste der State des Kalman-Filters das zu verfolgende Objekt abbilden. Dieser State, sowie der benötigte Statewechsel ist jedoch nicht problemlos zu definieren.

Das Problem beim Definieren des States liegt darin, dass das Objekt selbst keine wechselnden Zustände hat, sondern stets fest bleibt. Ein Ansatz wäre, die Position und Ausrichtung

3. State of the Art

des Objektes im State abzubilden. Bei einem Zustandsübergang müsste dann eine neue Position und Ausrichtung berechnet werden. Da sich das Objekt selbst nicht bewegt, müsste dieser Übergang in Abhängigkeit der Bewegung des AUVs umgesetzt werden. Es gibt jedoch keinen direkten Zusammenhang zwischen der Objektlage und der AUV Bewegung und somit kann kein Folgezustand berechnet werden.

3.2.2. Regressionsverfahren

Ein weiterer Lösungsansatz für das Schätzverfahren ist die Regression. Bei der Regression wird versucht, ein parametrisierbares Modell an gegebene Daten anzupassen. Dabei wird versucht, den Fehler der Daten im Bezug zur aus dem Modell generierten Kurve zu minimieren. Brundson nutzt in [Path estimation from GPS tracks\[4\]](#) einen Regressionsansatz, um aus fehlerbehafteten GPS Daten einen Pfad durch ein Stadtgebiet genauer zu bestimmen. Die GPS Daten ähneln den zu erwarteten Daten der Objekterkennung. Auch hier gibt es einen reellen Verlauf und fehlerbehaftete Messdaten zu beiden Seiten dieses Verlaufs.

Brundson berechnet die optimalen Modellparameter durch das Minimieren des quadrierten Fehlers jedes Punktes zur Kurve.

In der Abbildung 15 ist gut zu sehen, wie die Kurve nahezu den echten Pfad abbildet.

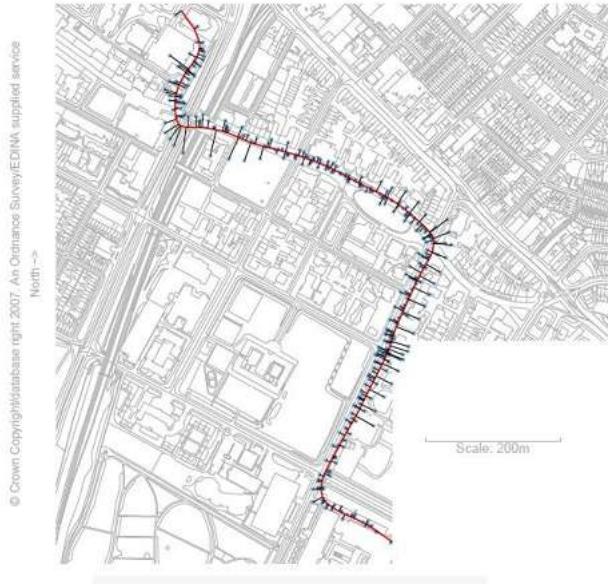


Abbildung 15: Regression angewandt auf Positionsangaben eines GPS-Empfängers aus [Path estimation from GPS tracks\[4\]](#). Die Fehler zu beiden Seiten des realen Fehlers werden gut durch die berechnete Kurve ausgeglichen

Eine sehr ähnliche Arbeit findet sich in [Autonomous Searching and Tracking of a River using an UAV\[14\]](#) von Rathinam et al.. Ziel der Arbeit ist es mithilfe eines UAVs (Unmanned Aerial Vehicle) den Verlauf eines Flusses zu bestimmen. Das Flugzeug ist mit

einer Kamera zur Detektion des Flusses ausgestattet.

Aus der Objekterkennung werden GPS Positionen des Flusses berechnet. Durch diese Daten wird dann mithilfe von Regression eine Kurve gelegt (siehe Abb. 16).

Im gelb gekennzeichneten Bereich im rechten Bild ist zu sehen, dass die Kurve an dieser Stelle nicht den Flussverlauf abbildet. Im selben Bereich ist im linken Bild zu sehen, dass die Objekterkennung keine Ergebnisse lieferte. Dies liegt daran, dass das Flugzeug dem engen Flussverlauf aufgrund der Trägheit der Steuerung nicht folgen konnte. Diese Trägheit ist in ähnlichen Rahmen auch im Unterwasserszenario zu erwarten.

Bemerkenswert ist, dass im roten Bereich ebenfalls keine Ergebnisse der Objekterkennung vorhanden sind, die Kurve jedoch trotzdem annähernd genau dem Flussverlauf folgt. Dies lässt sich darauf zurückführen, dass die letzten GPS Daten vor der Lücke die Abzweigung der Kurve andeuten, was im gelben Bereich nicht der Fall ist.



(a) Flusspositionen nach Objekterkennung



(b) Flussverlauf nach Curve Fitting

Abbildung 16: Regression angewendet auf GPS-Daten eines Flussverlaufs aus Autonomous Searching and Tracking of a River using an UAV[14]. Im gelben Bereich wird eine fehlender Sichtkontakt zum Fluss nicht optimal abgedeckt. Im roten Bereich ist die Kurve trotz fehlender Detektion nahezu optimal abgebildet.

Das Curve Fitting Verfahren eignet sich gut für die Problemstellung der Arbeit. Die zwei vorgestellten Arbeiten zeigen, dass sowohl Fehler durch Ausreißer abgefangen werden können, als auch Bereiche ohne Ergebnisse der Objekterkennung gut überbrückt werden können. Die genaue Beschreibung der eingesetzten Lösung und des von mir eingesetzten Models folgt im nächsten Kapitel.

In diesem Kapitel wird der von mir implementierte Lösungsansatz vorgestellt. Grundlegend gehe ich zuerst auf die Erweiterung der Simulationsumgebung und die implementierte Transformationskette ein.

Danach folgen genauere Ausführungen zu den Kernelementen der Arbeit, der Objekterkennung und dem Schätzverfahren.

Ein grundlegender Datentyp, der sich über alle Teile der Arbeit erstreckt, ist durch die Struktur *pointInFrame* [Listing 1] definiert. Diese Struktur bildet einen von der Objekterkennung detektierten Punkt des Objektes mit seiner Position und Orientierung ab. Zudem wird gespeichert, in welchem Referenzframe der Punkt angegeben ist. Neben diesen Positionsdaten sind zudem noch die Gütefaktoren der Objekterkennung angegeben (siehe hierfür Kapitel 6.2.2).

```

1 Point_In_Frame = struct;
2 Point_In_Frame.point = [0 0 0];
3 Point_In_Frame.direction = 0;
4 Point_In_Frame.peakheight = 0;
5 Point_In_Frame.area = 0;
6 Point_In_Frame.frame = frames.image
7 Point_In_Frame.numParts = 0;
8 Point_In_Frame.fitsBorder = false;
9 Point_In_Frame.relativeCount = 0;
10 Point_In_Frame.valid = false;
11 Point_In_Frame.theta = 0;
12 Point_In_Frame.phi = 0;
```

Listing 1: Initialisierung der *pointInFrame* Struktur die erkannte Punkte in verschiedenen Referenzkoordinatensystemen abbildet.

4.1. Simulationserweiterung

4.1.1. Steuerung

Wie im Kapitel 2.2 Grundlagen beschrieben wird in der bestehenden Simulation ein `lane follower controller`, der eine Linie zwischen einem `old_waypoint` und einem `new_waypoint` bildet, verwendet. Die Schnittstelle zur Steuerung bildet also die Kombination aus den beiden Wegpunkten. Die Berechnung der Wegpunkte wird auf Basis des Polynoms aus dem Schätzverfahren generiert.

Zunächst wird die Position des AUVs durch die aktuelle Transformationsmatrix in das alternative Weltkoordinatensystem (siehe Absatz 4.4 transformiert. Es wird der nächste Punkt auf dem Polynom zur transformierten Position des AUVs berechnet. Dieser Punkt dient als Zentrum für einen Kreis zur Bestimmung der Wegpunkte. Mithilfe der Kreisgleichung [Gleichung 1] werden die zwei Schnittpunkte des Polynoms mit dem Kreis berechnet. Da durch die Transformationsmatrix sichergestellt wird, dass das AUV in Richtung der *X – Achse* fährt kann problemlos der Schnittpunkt mit höherem *x* Wert als `next_waypoint` und dementsprechend der zweite als `old_waypoint` genommen werden. Es wird davon ausgegangen, dass bei einem solch kleinen Kreisradius (zwischen 5 und 10 Metern) nicht mehr als zwei Schnittpunkte zwischen Polynom und Kreis vorhanden sind. Sollte dies der Fall sein, wäre das Polynom viel zu stark gekrümmmt, um noch verfolgt zu werden. Im Szenario dieser Arbeit gibt es auch keine Objekte, die eine solch starke Krümmung aufweisen.

Der letzte Schritt besteht aus der Transformation der Wegpunkte in das reale VRML-Koordinatensystem mithilfe der inversen Transformationsmatrix. Das Verfahren ist in Abbildung 17 grafisch dargestellt.

$$0 = (X_{test} - Center_x)^2 + (Y_{test} - Center_y)^2 - r^2 \quad (1)$$

Gleichung 1: Kreisgleichung zum Test ob ein Punkt X_{test} , Y_{test} auf einem Kreis liegt. $Center_x$ und $Center_y$ bilden hierbei den Mittelpunkt eines Kreises mit Durchmesser r .

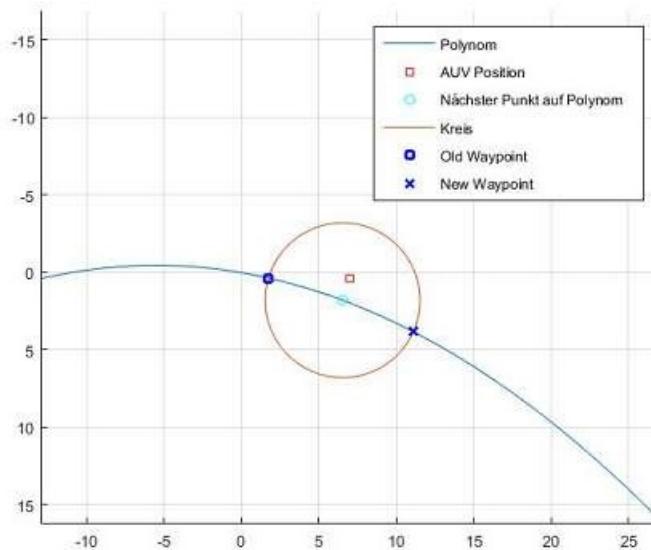
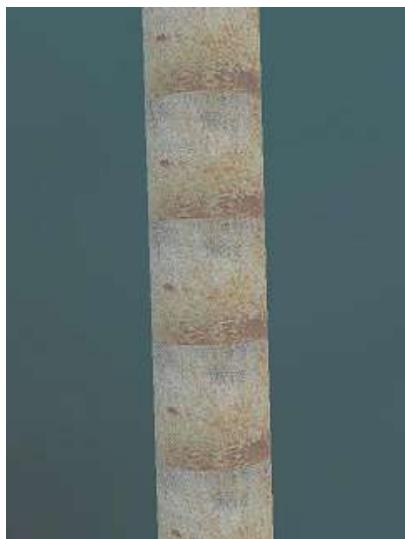


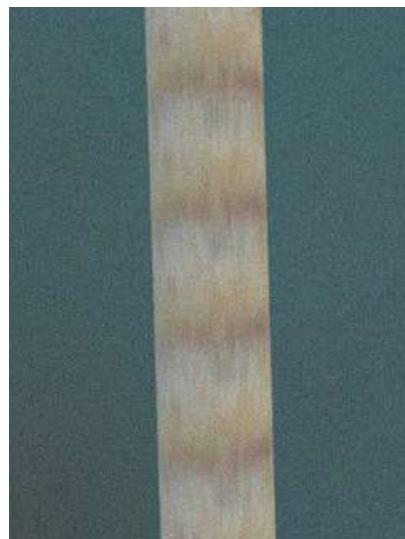
Abbildung 17: Verfahren zur Bestimmung der Wegpunkte. Der Wegpunkt wird im alternativen Weltkoordinatensystem bestimmt. Hierbei wird ein Kreis um den nächsten Punkt vom AUV auf dem Polygon bestimmt. Die Schnittpunkte des Kreises bilden die Wegpunkte für die AUV-Steuerung.

4.1.2. Kamerabilder

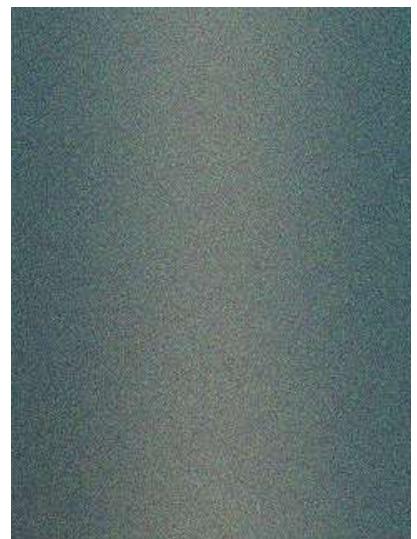
Da die Simulation in der ursprünglichen Form noch sehr *klinische* Bilder generierte mussten diese Bilder künstlich verschlechtert und die Sichtverhältnisse eingeschränkt werden, um realistische Eingangsbilder zu erzeugen. In Abbildung 18 ist von links nach rechts ein ursprüngliches Kamerabild, ein verschlechtertes Bild und ein sehr stark verschlechtertes Bild zu sehen. Die Testläufe der Arbeit wurden mit dem Verschlechterungsgrad des mittleren Bildes durchgeführt. Die Objekterkennung wurde zudem noch mit Bildern, wie dem rechten Bild getestet.



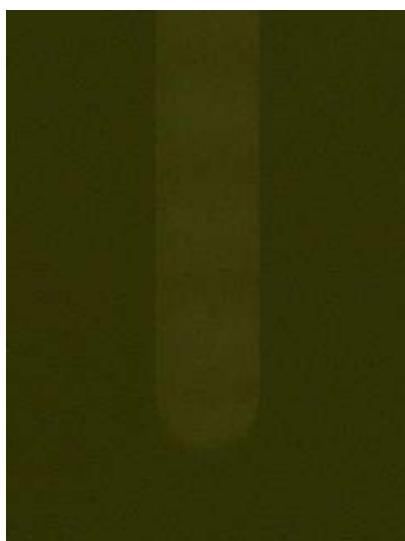
(a) Ursprüngliches Bild



(b) Bild verschlechtert mit leichtem *blur* und geringem Pixelrauschen



(c) Bild verschlechtert mit starkem *blur* und starkem Pixelrauschen



(d) Sichtverhältnisse verschlechtert und *blur* und geringem Pixelrauschen



(e) Sichtverhältnisse stark verschlechtert und *blur* und geringem Pixelrauschen



(f) Sichtverhältnisse sehr stark verschlechtert, simulierte Reflexion des Wassers *blur* und geringem Pixelrauschen

Abbildung 18: Simulationsbilder. a) zeigt das ursprüngliche Bild. In b) bis f) wird das Bild auf verschiedenen Arten verschlechtert.

4.2. Transformation

Wie bereits in der Einleitung beschrieben werden mehrere Koordinatensysteme genutzt. Zur sicheren Verwendung der Koordinatensysteme sind Transformationen unter den Systemen zwingend nötig. Eine Transformation besteht aus einer Rotation und einer Translation, die sich aus den Beziehungen der Systeme zueinander ergibt.

Im `enum frames` [Listing 2] sind die verschiedenen Frames definiert, zwischen denen eine Transformation möglich ist.

```

1 classdef frames < uint16
2 %FRAMES Summary of this class goes here
3 % Detailed explanation goes here
4 enumeration
5   image(0),cam(1),body(2),world(3),vrml(4)
6 end
7
8 end

```

Listing 2: Enumeration der Frames

Umgesetzt wird eine Transformation aus einem *source* Frame in einen *target* Frame durch die Funktion `transform` [Listing 3]. Die Transformation ist nur in eine Richtung möglich, da die inverse Transformation für diese Arbeit nicht benötigt wurde.

```

1 function transformed = transform(toTransform,targetFrame ,
2   height,PosEast_m,PosNorth_m,psi,phi,theta,cameraParameters
3 )
4 %TRANSFORM Summary of this function goes here
5 % Detailed explanation goes here
6 while(toTransform.frame~=targetFrame)
7   switch toTransform.frame
8     case frames.image
9       toTransform = pic2cam(toTransform,height,phi,
10                           theta,cameraParameters);
11     case frames.cam
12       toTransform = cam2body(toTransform);
13     case frames.body
14       toTransform = body2world(toTransform,psi,
15                               PosEast_m,PosNorth_m,height);
16     case frames.world
17       toTransform = world2vrml(toTransform);

```

```

14      end
15
16      transformed = toTransform;
17  end

```

Listing 3: Transformation von *source* in *target* Frame

4.2.1. Bild zu Kamera

Die verlustfreie Transformation von 2D-Pixelkoordinaten in 3D-Kamerakoordinaten ist mit einer Kamera nicht möglich. Jedoch lässt sich über das Wissen über die Entfernung zur Bildebene und die intrinsischen Kameraparameter eine ausreichend gute Transformation durchführen. Da die Kamera gerade nach unten gerichtet ist, entspricht die Entfernung zur Bildebene der Höhe des AUVs über dem Meeresboden, welche über die Sensorik bestimmt wird. Die intrinsischen Kameraparameter lassen sich über eine Kamerakalibrierung bestimmen. Die Kamerakalibrierung wurde mithilfe der MATLAB *Computer Vision System Toolbox* durchgeführt.

Da die resultierende Transformation am besten im Abstand der Kalibrierung funktioniert wurde die Kalibrierung in einem Abstand von 6 Metern durchgeführt, was im späteren Verlauf auch der gewünschte Abstand zum Boden ist.

Aus der Kamera Kalibrierung wird ein *CameraParameter*⁵ Objekt erzeugt, welches die Methode *pointsToWorld* bietet. Die Methode berechnet eine Projektionsmatrix aus den Kamera-Parametern und dem bekannten Abstand der Kamera zum Objekt. Mithilfe der Inversen dieser Matrix können dann Pixel in Kamerakoordinaten umgerechnet werden. Leichte Neigungswinkel, die während der Fahrt auftreten, können durch die Multiplikation mit der entsprechenden Rotationsmatrix herausgerechnet werden. Jedoch ist dabei zu beachten, dass durch die Neigungswinkel die Fläche, die die Kamera sieht, vergrößert wird. Dadurch bilden einzelne Pixel mehr Fläche ab und die Transformation wird ungenauer. Die *z* Koordinate ergibt sich aus dem Wissen, Objekte am Meeresboden zu betrachten und der Tatsache, dass die Höhe der Kamera über dem Meeresboden bekannt ist.

4.2.2. Kamera zu Body

Die Transformation vom Kamerakoordinatensystem zum Bodykoordinatensystem besteht aus einer Translation und einer Rotation, die durch die Montageposition der Kamera am AUV bestimmt wird [Kapitel 2.3.1].

Aufgrund der Verschiebung der Kamera zum Bodykoordinatenursprung (Schwerpunkt des AUVs) ergibt sich eine Translation um 1.3 in X Richtung und 0.25 in Z Richtung.

⁵ <https://de.mathworks.com/help/vision/ref/cameraparameters-class.html>

Die Rotation beträgt dabei 90° um die Z-Achse.

Somit ergibt sich die Tranformationsmatrix Gleichung 2

$$\begin{pmatrix} x_{body} \\ y_{body} \\ z_{body} \\ 1 \end{pmatrix} = \begin{pmatrix} 0 & -1 & 0 & 1.3 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0.25 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} x_{cam} \\ y_{cam} \\ z_{cam} \\ 1 \end{pmatrix} \quad (2)$$

Gleichung 2: Transformation der Kamerakoordinaten zu Bodykoordinaten. Die Kamerakoordinaten werden um 1,3m auf der X-Achse und 0,25m auf der Z-Achse verschoben. Außerdem wird eine Rotation um 90° um die Z-Achse durchgeführt.

4.2.3. Body zu Welt

Die Transformation vom Bodykoordinatensystem in das Weltkoordinatensystem ist wieder eine Translation und eine Rotation nötig. Aus der Definition der Koordinatensysteme ist zunächst eine Rotation um 180° um die X-Achse nötig. Die Translation ergibt sich aus der Position des AUVs (Position Nord/Ost in Metern).

Die Rotation wird durch die Ausrichtung des AUVs in der Welt (Yaw [Abb. 5]) bestimmt. Somit ergibt sich die Tranformationsmatrix Gleichung 3

$$\begin{pmatrix} x_{world} \\ y_{world} \\ z_{world} \\ 1 \end{pmatrix} = \begin{pmatrix} \cos(yaw) & -\sin(yaw) & 0 & Pos_{north} \\ \sin(yaw) & \cos(yaw) & 0 & Pos_{east} \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \left(\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} x_{body} \\ y_{body} \\ z_{body} \\ 1 \end{pmatrix} \right) \quad (3)$$

Gleichung 3: Transformation der Bodykoordinaten zu Weltkoordinaten. Zunächst werden die Body-Koordinaten um 180° um die X-Achse rotiert. Im Anschluss findet eine Translation zu der Position des AUVs in der Welt und eine Rotation um die Z-Achse, die die Ausrichtung des AUVs abbildet, statt.

4.2.4. Welt zu VRML

Für die Transformation von Weltkoordinaten in VRML Koordinaten ist nur eine Rotation um -90° um die X-Achse nötig [Abb. 4].

$$\begin{pmatrix} x_{vrm} \\ y_{vrm} \\ z_{vrm} \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & -1 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} x_{body} \\ y_{body} \\ z_{body} \\ 1 \end{pmatrix} \quad (4)$$

Gleichung 4: Transformation von Weltkoordinaten in VRML Koordinaten. Hierfür ist nur eine Rotation um -90° um die X-Achse nötig.

4.3. Objekterkennung

In diesem Kapitel wird die umgesetzte Objekterkennung beschrieben. Dabei wird aus einem Rohbild der Kamera ein *pointInFrame*-Objekt erzeugt. Grob besteht die Objekterkennung aus zwei Schritten. Zuerst wird aus dem Rohbild ein Binärbild erzeugt und im zweiten Schritt dann im Binärbild das gesuchte Objekt detektiert.

4.3.1. Binärbild mit Template

Die Objekterkennung basiert auf einem ähnlichen Verfahren wie das vorgestellte CSurvey Projekt[1].

Da ein Farberkennung aufgrund der Sichtbedingungen nicht in Frage kommt wird im ersten Schritt das RGB-Bild in ein Graustufenbild umgewandelt. Die erste Idee war es hier das Helligkeitsbild zu betrachten, da ein gesuchtes Objekt einen höheren Helligkeitswert besitzt, als der Meeresboden (siehe Abb. 20b und 21b).

Aus Erfahrungswerten früherer Projekte riet Christopher Gaudig mir, die Rotwerte der Bilder zu betrachten, da oftmals der Meeresboden und trübes Wasser geringe Rotwerte haben. In den Abbildungen 20c und 21c ist dies zu beobachten. Die Kurven sehen denen der Helligkeitswerte sehr ähnlich, jedoch sind die Ausschläge des Objektes in den Rotwerten höher.

Im nächsten Schritt wird mithilfe eines Templates [Abb. 19] ein Binärbild erzeugt. Das Template zeichnet sich durch drei Pixelangaben aus. Die *Testpixel* (rot) geben einen Bereich an, der im aktuellen Schritt geprüft wird. Die *Checkpixel* (blau) geben den Bereich rechts und links neben dem Testbereich an und bilden den Referenzwert. Die *Borderpixel* (grün) geben einen Bereich zwischen Test- und Checkbereich an, der ignoriert wird. Durch das Ignorieren des Bereichs kann ein langsamer regelmäßiger Übergang, der bei Betrachtung der direkten Nachbarpixeln des Testbereichs als Checkbereich zu einem geringen Templatewert führt, trotzdem noch einen hohen Templatewert ergeben. Jedes Pixel dient einmal als Mittelpunkt des Testbereichs, um zu entscheiden, ob das betrachte Pixel Teil des Objektes sein kann. Dies ist der Fall, wenn der Wert des Pixels [Gleichung 5] einen Schwellwert (rote Linie) übersteigt.

Kann man die grauen mit legends gut genug erkennen?

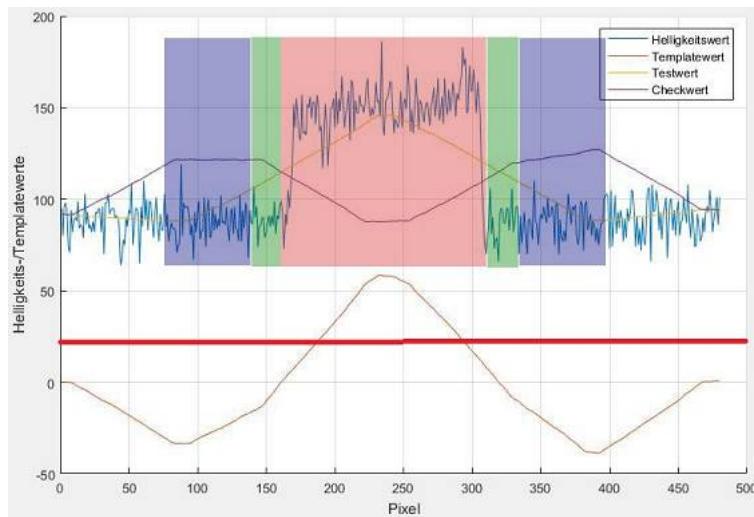


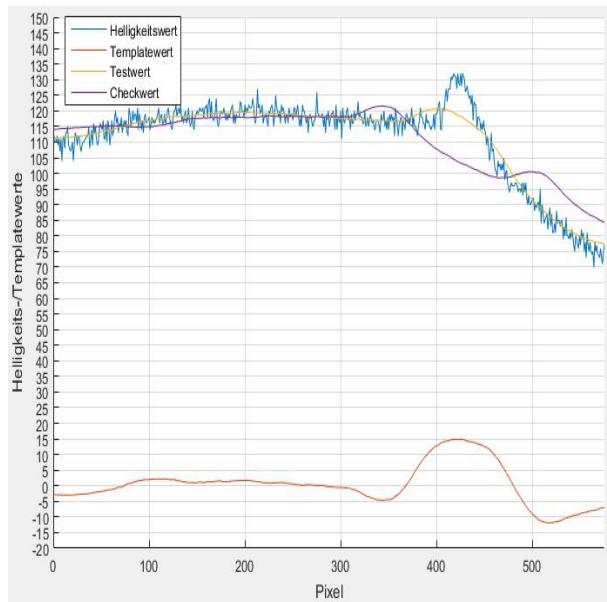
Abbildung 19: Template zum Bestimmen des Binärbilds. Getestet wird das Pixel im Zentrum des Testbereichs (rot). Der Templatewert ergibt sich aus der Subtraktion des Durchschnitts im Checkbereich (blau) vom Durchschnitt des Testbereichs (rot). Der Borderbereich (grün) wird dabei nicht beachtet.

$$TV = \frac{\sum(\text{Testpixel})}{\# TP} - \frac{\sum(\text{Checkpixel})}{2 \cdot \# CP} \quad (5)$$

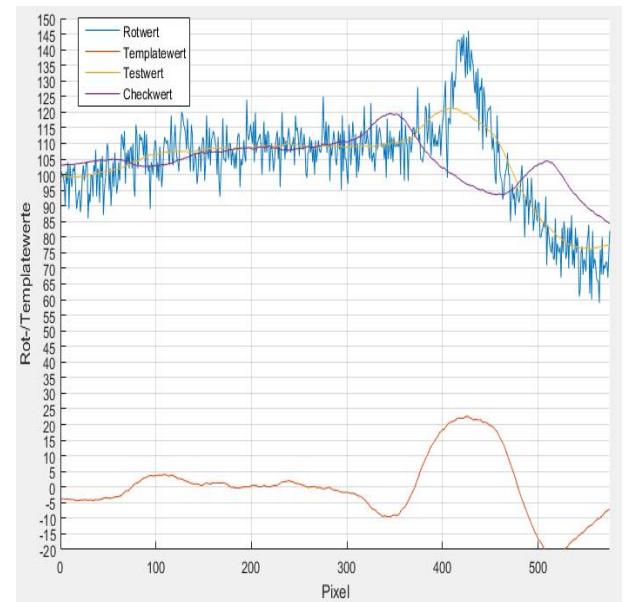
Gleichung 5: Templatewertberechnung für ein Pixel als Formelausdruck.



(a) Originalbild

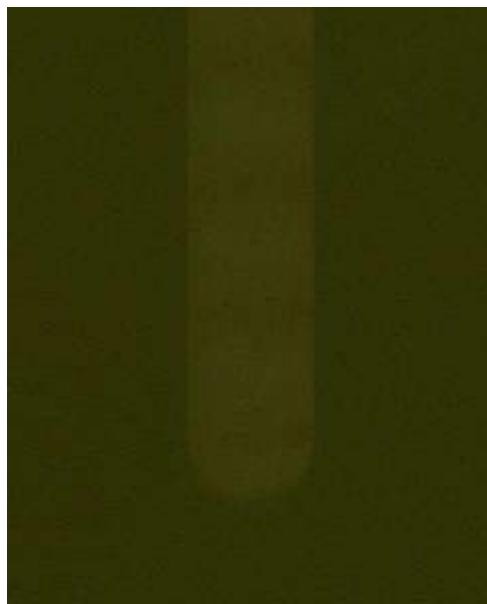


(b) Helligkeitsverlauf einer Bildzeile im oberen Drittel des Bildes

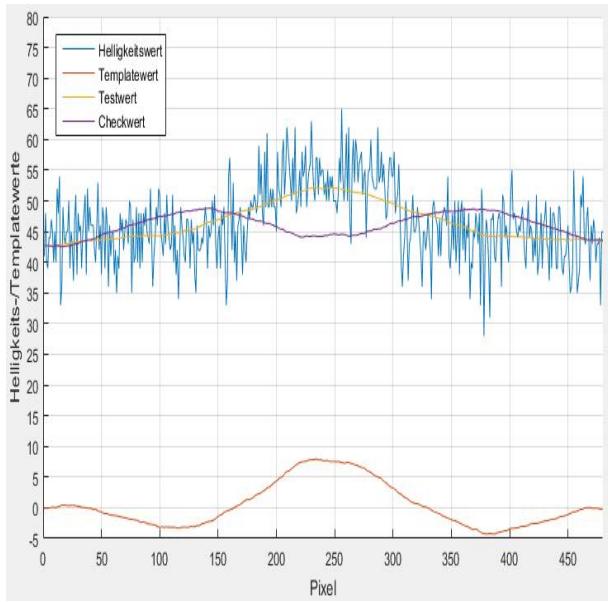


(c) Rotwertverlauf einer Bildzeile im oberen Drittel des Bildes

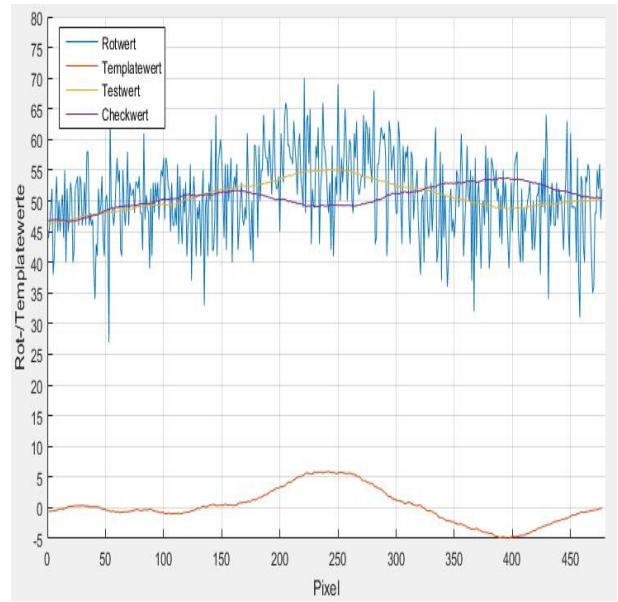
Abbildung 20: Helligkeit und Rotwert im echten Testbild



(a) Originalbild der Simulation



(b) Helligkeitsverlauf einer Bildzeile im oberen Drittel des Bildes



(c) Rotwertverlauf einer Bildzeile im oberen Drittel des Bildes

Abbildung 21: Helligkeit und Rotwert im Simulationsbild

4.3.2. RANSAC auf Binärbild

Im weiteren Verlauf wird auf dem Binärbild gearbeitet. Nach dem Vorbild von Wang et al. [18] wird das Bild in drei Segmente unterteilt.

In jedem Segment wird dann mithilfe des RANSAC -Algorithmus ein Rechteck gesucht [Listing 4]. Der Algorithmus sampled verschiedene Rechtecke im Segment. Dieses Rechteck wird durch einen Mittelpunkt, eine Orientierung, der Breite und der Höhe definiert.

Die Höhe ergibt sich aus der Höhe des Segmentes und die Breite wird durch die erwartete Breite des Objektes festgelegt. Mittelpunkt und Orientierung werden in jedem Iterations-schritt zufällig gewählt.

Für jeden Punkt des Binärbilds wird dann geprüft, ob er im Rechteck liegt (ein Inlier ist). Gemäß des RANSAC wird das Rechteck mit den meisten Inliern gewählt.

```

1 function ransac(segment, height, width, minInlier, iterNum)
2     maxInlier = 0;
3     orientations = -pi/4:0.05:pi/4;
4     bestCenter = None;
5     bestOrientation = None;
6     for i = 1:iterNum
7         boxCenter = selectRandomPoint(segment);
8         boxOrientation = selectRandomValue(
9             orientations);
10        inliers = findPointsInBox(segment, box=[ 
11            boxCenter, boxOrientation, height, width]);
12
13        if(len(inliers) > minInlier && len(inliers) >
14            maxInlier)
15            maxInlier = len(inliers)
16            bestCenter = boxCenter;
17            bestOrientation = boxOrientation;
18        end
19    end
20
21 end

```

Listing 4: Eingesetzter RANSAC als Pseudocode

Somit gibt es für jedes Bild bis zu drei Objektposen. Durch das unterteilen in Segmente lässt sich zum Einen bestimmen, in wie vielen Segmenten ein Objekt erkannt wurde (entspricht der *Länge* des Objektes im Bild). Desweiteren kann ein gebogener Verlauf oder ein abgeknicktes Objekt im Bild sinnvoll erkannt werden.

In den ersten Tests dieses Verfahrens ist ersichtlich geworden, dass es einen Tradeoff zwischen Geschwindigkeit und Erkennungsgüte gab. Die Erkennung wurde besser, je mehr maximale Iterationen dem RANSAC erlaubt wurden. Da der RANSAC jedoch auf jedes der drei Segmente separat angewendet wird, wird bei steigender Iterationsanzahl die Geschwindigkeit deutlich reduziert. Für eine zuverlässige Erkennung waren zu viele Iterationen nötig, sodass das Verfahren nicht einsetzbar wäre.

richtige
wort-
wahl?

Als Lösung für dieses Probleme habe ich die möglichen erzeugten Rechtecke für den RANSAC begrenzt. Da das Template nur in horizontaler Richtung auf das Bild angewendet wird, sind horizontal liegende Objekte im Binärbild nicht sichtbar. Aufgrund dieser Tatsache lassen sich die Orientierungen auf einen Bereich begrenzen, anstatt diese komplett zufällig zu wählen. Durch diese Maßnahme wurden die benötigten Iterationen für ein zuverlässiges Ergebnis drastisch reduziert. Jedoch steigt auch die Gefahr Orientierungen nicht mehr richtig zu erkennen, wie in Abbildung 22 gezeigt.

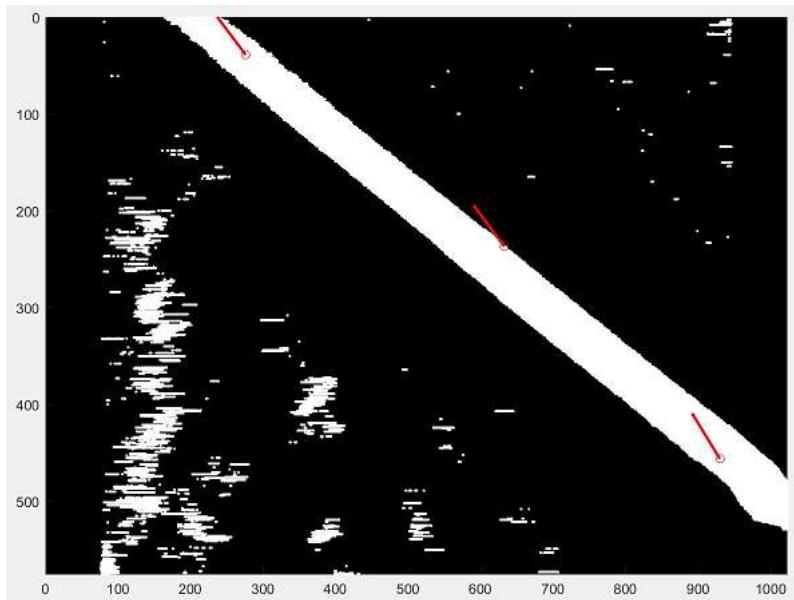


Abbildung 22: Falsch detektierte Bestimmung der Objektorientierung aufgrund der Beschränkung der Ausrichtungen für den RANSAC

Der zweite Faktor, der die Geschwindigkeit der Objekterkennung verringerte, ist die Menge der Punkte im Binärbild. So musste für jede Iteration des RANSAC für jeden Punkt geprüft werden, ob der Punkt im Rechteck liegt. In den Testbildern der Simulation lag die Anzahl der Punkte teilweise bei weit über 10000, was in Kombination mit 200 Iterationen zu einer inakzeptablen Laufzeit von ca. 5 Sekunden pro Bild führte.

Zum Lösen dieses Problems wurde vor dem Einsatz des RANSAC die Punktanzahl verringert, indem nur jedes dritte Pixel betrachtet wird und dieses den Mittelwert aller seiner Nachbarpixel erhält. Somit konnte die Punktanzahl zuverlässig auf unter 2000 verringert werden, was zu einer deutlichen Beschleunigung (ca. 1 Sekunde pro Bild) ohne nennenswerte Verschlechterung der Ergebnisse führte.

Grafik?

4.4. Schätzverfahren

In diesem Abschnitt wird das implementierte Schätzverfahren erläutert. Das Verfahren nutzt die Ergebnisse der Bilderkennung und versucht mithilfe der Regression ein Polynom f zweiten Grades durch alle erkannten Punkte in Betrachtung ihrer Orientierung zu fitten. Das Verfahren basiert auf dem *Least-Squares* Verfahren[15], wobei versucht wird die Gleichung 6 zu minimieren.

x_i und y_i sind hierbei die Koordinaten der erkannten Punkte. Es wird über alle Punkte summiert der quadratische Fehler vom Funktionswert zu gegebenen Parametern zum y aus der Bilderkennung berechnet. $f(p, x)$ ist eine beliebige Funktion, die x in Abhängigkeit von p auf eine reelle Zahl abbildet.

$$err = \sum_i (f(p, x_i) - y_i)^2 \quad (6)$$

Gleichung 6: Least Squares Ansatz

Über die Zeit gesehen wird die Menge an detektierten Punkten immer größer. Da das Ziel des Verfahrens die Vorhersage des Objektverlaufs ist, ist eine gute Extrapolation wichtiger als das richtige Abbilden aller Punkte der Vergangenheit. Für die Extrapolation ist anzunehmen, dass neuere Punkte für den Verlauf wichtiger sind als ältere. Aus diesem Grund werden die Punkte über die Zeit exponentiell abnehmend gewichtet. Somit erhalten aktuelle Punkte einen höheren Stellenwert als ältere, ohne jedoch alte Punkte komplett zu verwerfen.

Um diese Anforderungen umzusetzen habe ich eine Erweiterung des *Least-Squares* genutzt, den *Weighted-Least-Squares*[Gleichung 7]

$$err = \sum_i w_i \cdot (f(p, x_i) - y_i)^2 \quad (7)$$

Gleichung 7: Weighted Least Squares Verfahren

Das *Weighted-Least-Squares* Verfahren bietet eine gute Grundlage für die Regression. Es bleiben jedoch noch einige Probleme, die das Verfahren in der Form nicht lösen kann.

1. Beachtung der Orientierung erkannter Punkte
2. Bedingungen für die Kurve (z.B. maximale Steigung)

3. Schätzungen, für Punktverläufe, die sich nicht durch ein einzelnes Polynom darstellen lassen

Zum Lösen der ersten zwei Probleme bietet die MATLAB Funktion *fmincon*⁶ aus der Optimization Toolbox eine geeignete Lösung. Die Funktion bietet die Möglichkeit eine Funktion $F(p)$ zu minimieren, wobei mit $c(p) \leq 0$ eine Bedingung erfüllt werden muss. Die Funktion $c(p, x_i)$ [Gleichung 8] berechnet über den Funktionsverlauf von $f(p, x)$ mithilfe der Ableitung $f'(p, x)$ die Steigung in jedem Punkt x_i . Da *fmincon* prüft, ob die Bedingungsfunktion kleiner 0 ist wird von der Steigung ein Maximalwert (\max_{slope}) abgezogen (*Erfüllt 2.*).

$$c(p, x_i) = f'(p, x_i) - \max_{slope} \quad (8)$$

Gleichung 8: Funktion zum überprüfen, ob die Steigung einen Maximalwert nicht übersteigt.

Die Funktion $F(p)$ wird als $F(p, x, y, s, w, n, m, tau)$ [Gleichung 9] definiert, wobei x und y wieder die Punkte der Bilderkennung darstellen, s die erkannte Orientierung im Punkt und w das Gewicht. Die Funktion F besteht aus einer Linearkombination der Funktionen g und h , wobei g den summierten Fehler der Position [Gleichung 10] (x, y Koordinaten) und h den summierten Fehler der Orientierung [Gleichung 11] mithilfe des *Weighted-Least-Squares* Verfahren berechnen (*Erfüllt 1.*). n und m gewichten, wie stark die einzelnen Fehlerarten (Position und Orientierung) in den Gesamtfehler für die gegebenen Funktionsparameter p eingehen.

Um die erhaltenen Polynome einschränken zu können, wurde F noch gemäß der *Tikhonov Regularisierung* [10] angepasst. Durch die *Tikhonov Regularisierung* können wenig gekrümmte Kurven bevorzugt werden, was für einen ruhigeren Fahrtverlauf sorgen kann.

$$F(p) = F(p, x, y, s, w, n, m, tau) = n \cdot g(p, x, y, w) + m \cdot h(p, x, s, w) + tau \cdot p \quad (9)$$

$$g(p, x, y, w) = \sum_i w_i \cdot (f(p, x_i) - y_i)^2 \quad (10)$$

$$h(p, x, s, w) = \sum_i w_i \cdot (f'(p, x_i) - s_i)^2 \quad (11)$$

Gleichung 9: Zusammensetzung der Funktion F , die minimiert wird.

Um das Problem 3. zu lösen, betrachten wir Abbildung ???. Das Objekt ist hierbei so gelegen, dass kein Polynom zweiten Grades sinnvoll durch die Daten gelegt werden kann

⁶ <https://de.mathworks.com/help/optim/ug/fmincon.html>

und außerdem ein Teilabschnitt parallel zur Y – Achse verläuft. Der letzte Fall ist zu beachten, da ein solcher Verlauf durch eine unendliche Steigung im Polynom abgebildet werden müsste.

Als Lösung für dieses Problem führe ich ein alternatives Weltkoordinatensystem. Dieses unterscheidet sich durch eine Transformation vom echten Weltkoordinatensystem.

Nach jeder Regression wird das berechnete Polynom in den aktuellsten Punkten getestet. Sollte dabei ein gewisser Fehlerschwellwert überschritten werden eine neue Transformation berechnet [Listing 5]. Diese neue Transformation besteht aus einer Translation zum Punkt mit dem größten x -Wert und einer Rotation um die durchschnittliche Ausrichtung der neuesten Punkte. Neben der Transformationsmatrix wird auch die Inverse der Matrix gespeichert, die für die Wegpunktberechnung [Kapitel 4.1.1] wichtig ist. Da die Transformation ausgelöst wird, sobald das Polynom in den neuesten Punkten einen zu großen Fehler ergibt werden nach dem Speichern der Matrizen alle Punkte, bis auf die neuesten verworfen, um ein potentiell besseres Polynom für die Extrapolation zu ermöglichen.

Sobald eine beschriebene Transformation gespeichert wurde, werden alle Punkte vor der Regression in das alternative Koordinatensystem transformiert. Durch diese Transformation sind die erkannten Punkte entlang der X – Achse gelegen und somit ist es möglich, stets ein geeignetes Polynom für die Punkte zu finden. Durch die Translation liegen die Punkte stets nah am Ursprung, was den Parameterraum für die Regression verringert und somit zu schnelleren Ergebnissen führt.

```

1 function polynomFit(points ,maxError)
2     actualTransform = loadActualTransformation();
3     points_T = transformPoints(points ,actualTransform);
4
5     polynom = regression(points_T);
6     error = calculateError(points_T ,polynom);
7     if (error >= maxError)
8         translation = findGreatestXValue(points_T);
9         rotation = averageDirectionOfLastPoints(
10             points_T);
11        newTransform = createTransMatrix(-translation
12                                         ,-rotation) * actualTransform;
13        saveNewTransform();
14    end
15 end

```

hier noch gra-phen zur trans-forma-tion

Listing 5: Pseudocode des Schätzverfahrens

5. Tests und Evaluation

In diesem Kapitel werden die Tests der Arbeit zusammengefasst. Zuerst werden spezifische Tests für die Güte der Objekterkennung beschrieben. Im zweiten Teil werden verschiedene Testläufe der Simulation mit verschiedenen Objektverläufen angeführt.

5.1. Tests Objekterkennung

Die Objekterkennung wurde auf drei Arten getestet. Für diese Arbeit ist eine verlässliche Erkennung auf Simulationsbildern wichtig. Aus diesem Grund beziehen sich die ersten Tests auf Simulationsbildern. Der dritte Test dient der Evaluation der genutzten Methode in Bezug auf Echtdaten.

Die erste Testreihe besteht aus Bildern, auf denen das Objekt gut zu sehen ist und nur leicht verdeckt ist. Außerdem werden die Bilder so gewählt, dass teilweise in einzelnen Segmenten kein Objekt zu sehen ist und dass das Objekt über in verschiedenen Segmente unterschiedlich Orientiert sind.

In der zweiten Testreihe werden die gleichen Bilder künstlich verschlechtert, um Bewegungsunschärfe und Rauschen der Kamera zu simulieren und die Grenzen der Objekterkennung im Bezug zur Bildqualität ermittelt. Für beide Testreihen wurden auch Vergleichsbilder ohne Objekt genommen.

Erste Testreihe

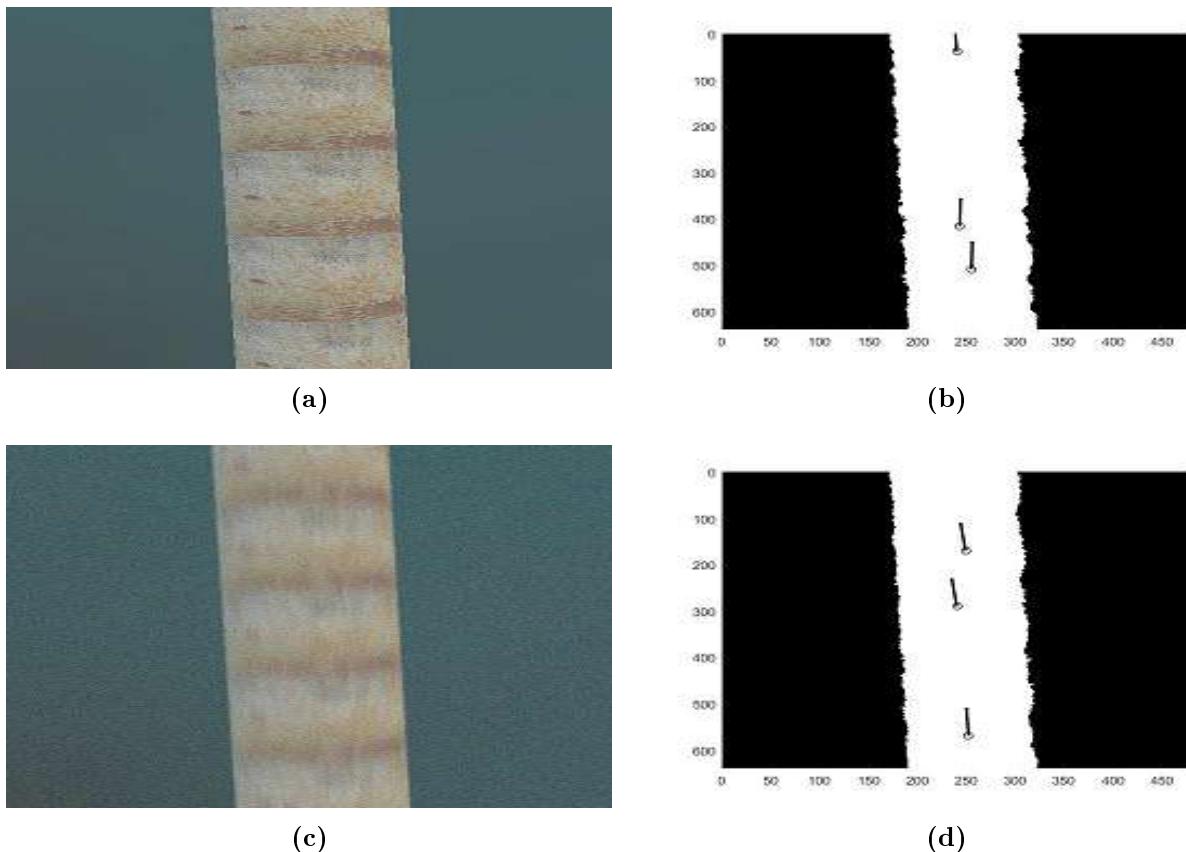
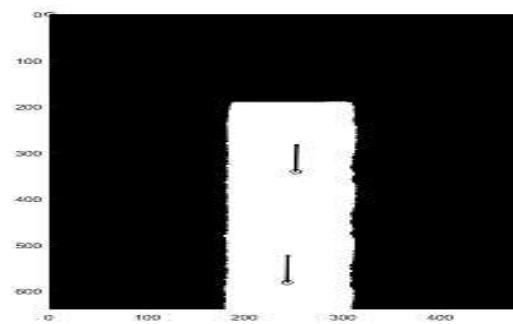


Abbildung 23: Ein gerades Objekt, dass ohne Einschränkungen zu sehen ist wird unter verschiedenen Sichtbedingungen und Bildqualität getestet.

bitte
erst ab
dritte
Testrei-
he lesen



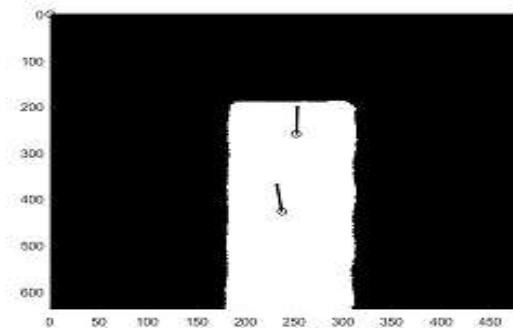
(a)



(b)



(c)

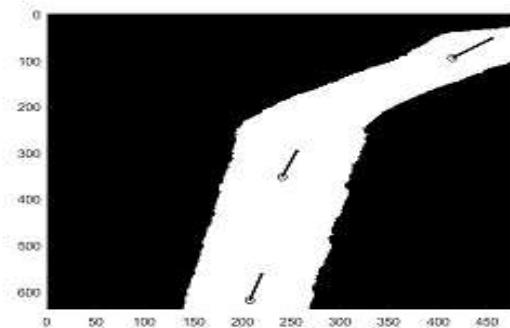


(d)

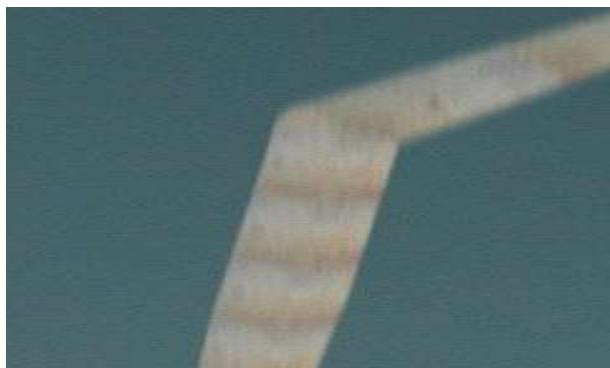
Abbildung 24



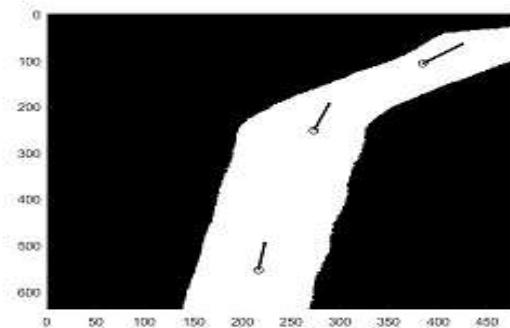
(a)



(b)

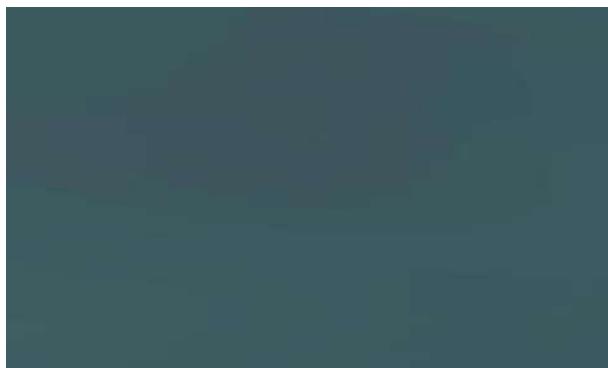


(c)

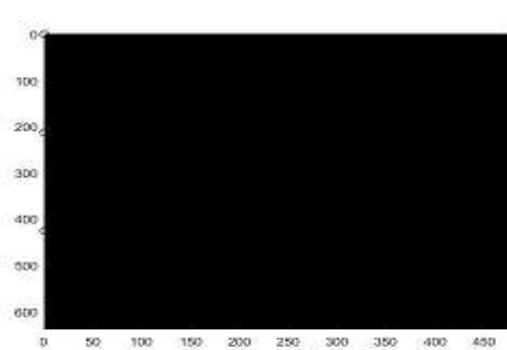


(d)

Abbildung 25



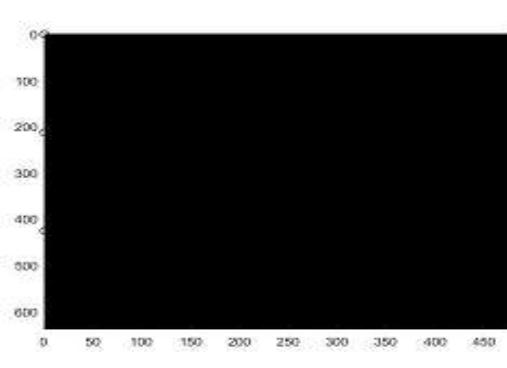
(a)



(b)



(c)



(d)

Abbildung 26

Dritte Testreihe

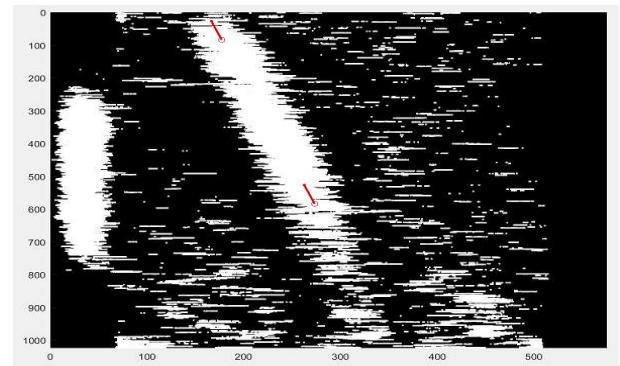
Um zu testen, ob das Verfahren auch bei echten Bildern funktioniert wurden insgesamt 12 Bilder [Anhang E.1] aus einem Testlauf des AUVs *DAGON*⁷ während des Projektes *CUSLAM*⁸ im Unisee getestet. In einigen Bildern, wie in Abbildung 27b oder 27d ist die Pipeline schwer zu erkennen. Dadurch muss der Schwellwert für das Template entsprechend niedrig gesetzt werden, was zu vielen Punkten im Binärbild führt, die nicht zum Objekt gehören. In Bildern, in denen die Pipeline direkt angestrahlt wird und klar heller ist, wie in Abbildung 28 ist das Objekt wieder klar heller als der Hintergrund, der Schwellwert kann höher angesetzt werden, um weniger Störpunkte zu erhalten.

⁷ <http://robotik.dfki-bremen.de/de/forschung/robotersysteme/dagon.html>

⁸ <http://robotik.dfki-bremen.de/de/forschung/projekte/cuslam.html>



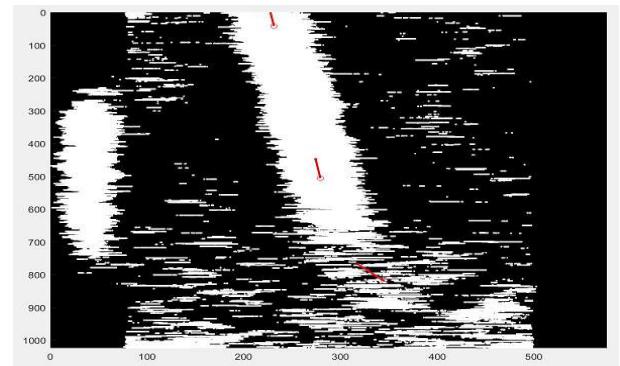
(a)



(b)

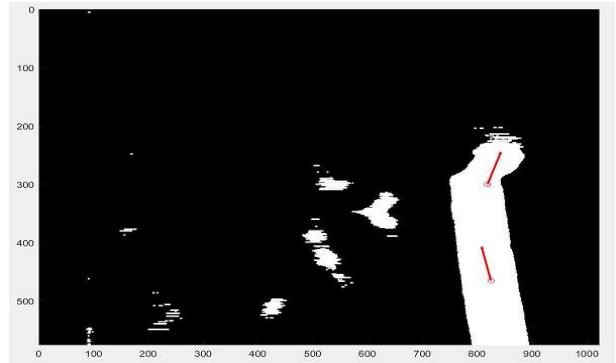


(c)



(d)

Abbildung 27: Tests der Objekterkennung auf realen Bilder aufgenommen im Unisee vom AUV *DAGON*. Trotz sehr schlechten Sichtbedingungen und vielen Störpunkten im Binärbild wird die Pipeline in den oberen zwei Segmenten gut erkannt. In *d*) ist im unteren Bereich eine Fehldetektion aufgrund der hohen Störpunkteldichte in diesem Bereich. Die Randbereiche werden während des Binärisierungsprozess am Bild hinzugefügt, um dass Template auch auf den ersten und letzten Pixeln anwenden zu können. Diese Bereiche werden bei der Detektion nicht betrachtet.



(a)

(b)

Abbildung 28: Test der Objekterkennung auf einem realen Bild aufgenommen im Unisee vom AUV *DAGON*. Die Pipeline reflektiert sehr stark und hebt sich dadurch deutlich vom Hintergrund ab. Jedoch gibt es eine starke Reflexion des Wassers nah an der Pipeline, was zu einer Fehldetektion im zweiten Segment führt.

In den durchgeföhrten Tests wird deutlich, dass die Objekterkennung unter verschiedensten Sichtbedingungen gute Ergebnisse liefert. Abhängig ist die zuverlässige Detektion vom Templateschwellwert für die Binärisierung des Bildes. Je stärker sich das Objekt vom Hintergrund abhebt, desto höher kann der Schwellwert gewählt werden (vgl. Kapitel 4.3.1). Bei einem geringen Schwellwert gibt es im Binärbild mehr Störpunkte als bei einem höheren (vgl. Abb. 27 mit 28).

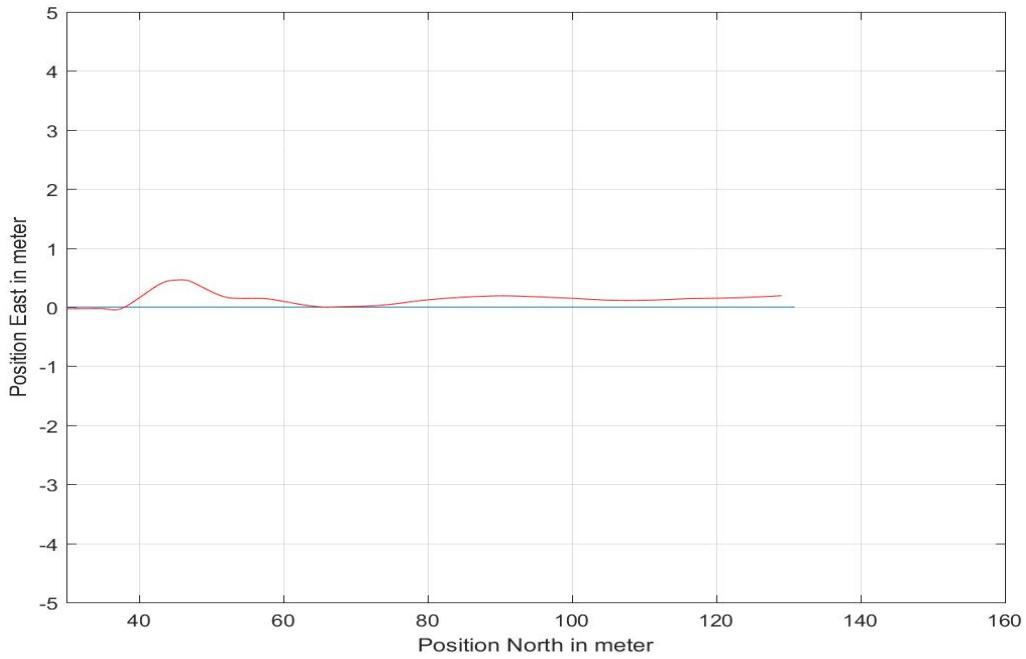
5.2. Testläufe

Im folgenden werden die verschiedenen Testläufe genau beschrieben. Für alle Testläufe gilt, dass das AUV zuerst 30 Meter geradeaus fährt, bevor es auf das Objekt trifft, damit eine stabile Fahrt erreicht wird und die Schwankungen beim anfänglichen Beschleunigen die Ergebnisse nicht verfälschen. Ebenso wird auch gewährleistet, dass das AUV stets direkt auf das Objekt trifft, da dass Explorieren und Auffinden des Objektes nicht Teil der Arbeit ist.

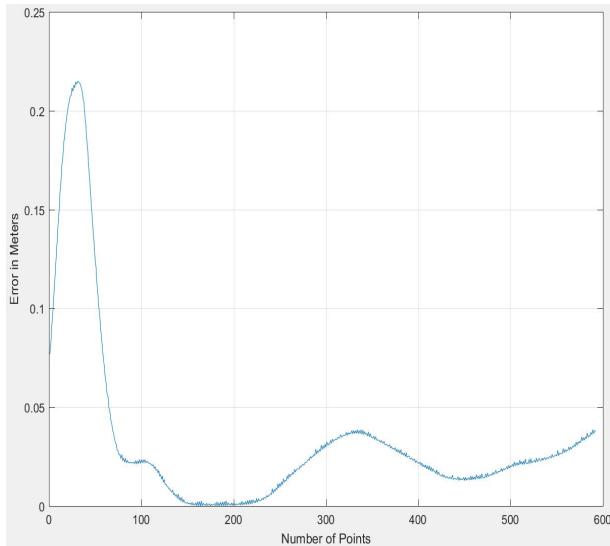
Zu jedem Testlauf befindet sich auf der CD ein Video, in dem das AUV von oben, die Rohbilder der Kamera, die Ausgabe der Objekterkennung und das berechnete Polynom zu sehen ist.

5.2.1. Gerader Verlauf

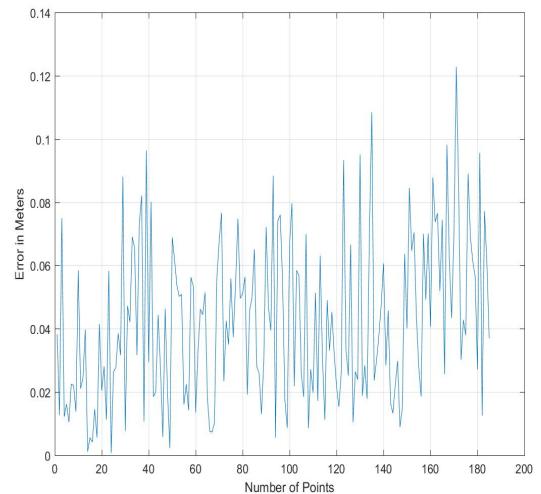
Für die ersten Tests wurde ein 100 Meter langes Objekt gerade in die Simulationsumgebung eingefügt. Dieses Objekt ist in mehreren Bereichen vom Meeresboden leicht bis komplett bedeckt.



(a) Fahrtverlauf des AUVs (rot) an einem geraden Objekt (blau). Nach erstem Sichtkontakt zum Objekt ist ein einpendeln auf die gerade Linie zu beobachten.



(b) Fehler der AUV Position zur echten Position des Objektes. Auch hier ist zu beobachten, dass ein großer Fehler zu Beginn des Objektes auftritt, der beim Fahrtverlauf weiter verringert wird.



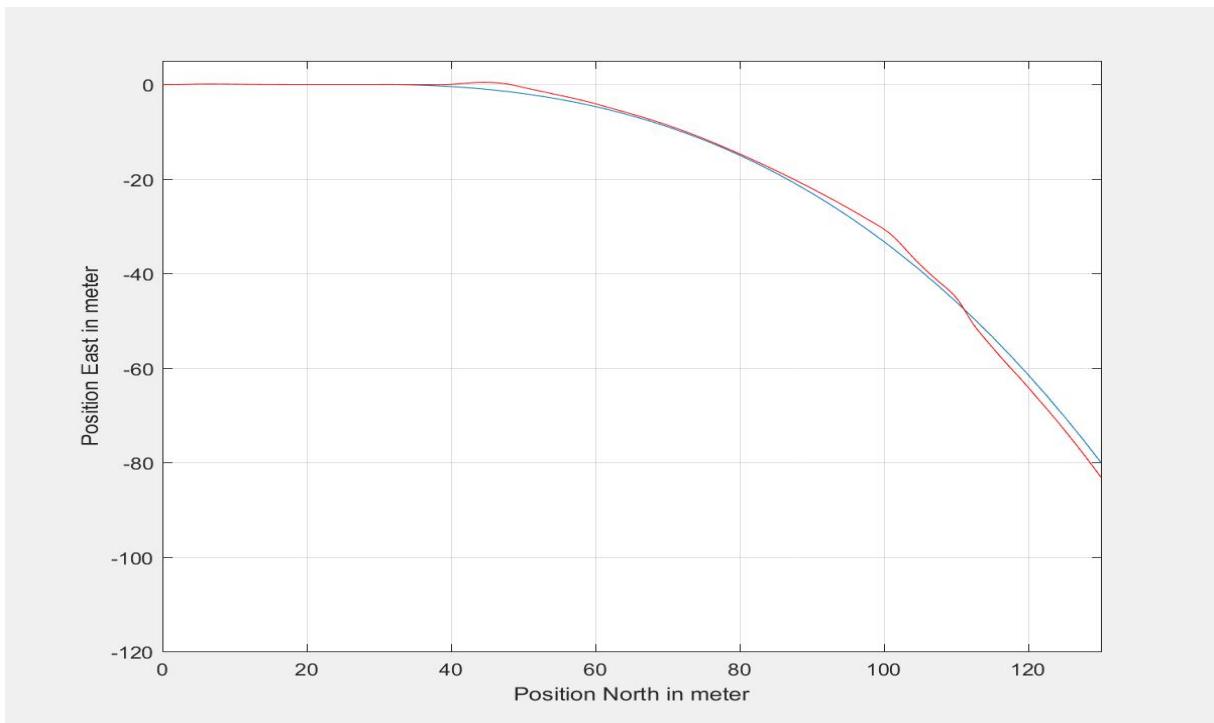
(c) Fehler der detektierten Objektposition zur echten Objektposition. In Betrachtung von b) ist zu beobachten, dass der Fehler der detektierten Objektposition größer ist, als der Fehler im daraus resultierenden Fahrtverlauf.

Abbildung 29: Testlauf an einem geraden Objekt. Nach anfänglich größeren Fehler folgt das AUV dem Objekt mit nur sehr geringem Fehler. Das Einpendeln ist auf die Berechnung des Polynoms zurückzuführen, da bei wenigen Punkten zu Beginn der Verlauf noch nicht eindeutig als Gerade bestimmbar ist. Siehe hierfür Kapitel 5.3.1

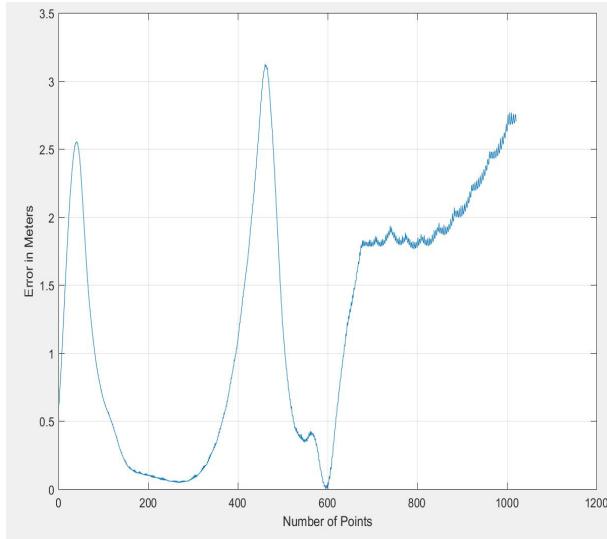
5.2.2. Kurve

Nach den Tests zum geraden Verlauf wurden kurvige Objekte mithilfe von Polynomial- und Exponentialfunktionen in die Simulation eingefügt. Hierbei wurde darauf geachtet kein Polynom zweiten Grades zu verwenden, um dem Regressionsverfahren keine perfekte Lösung zu bieten.

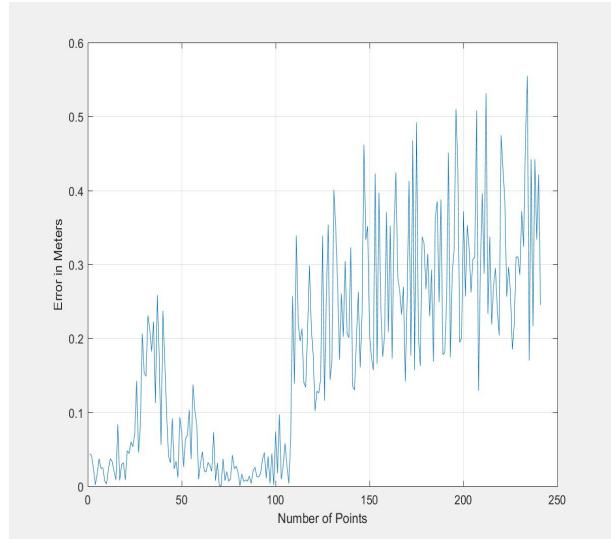
Ziel dieser Tests ist es zu zeigen, dass das Folgen einer Links- sowie Rechtskurve und auch ein wechseln zwischen beiden Kurvenarten möglich sind. Für letzteres wurde eine Sinuskurve genutzt, um ein entsprechendes Objekt zu erzeugen.



(a) Fahrtverlauf (rot) bei einer Kurve (blau).

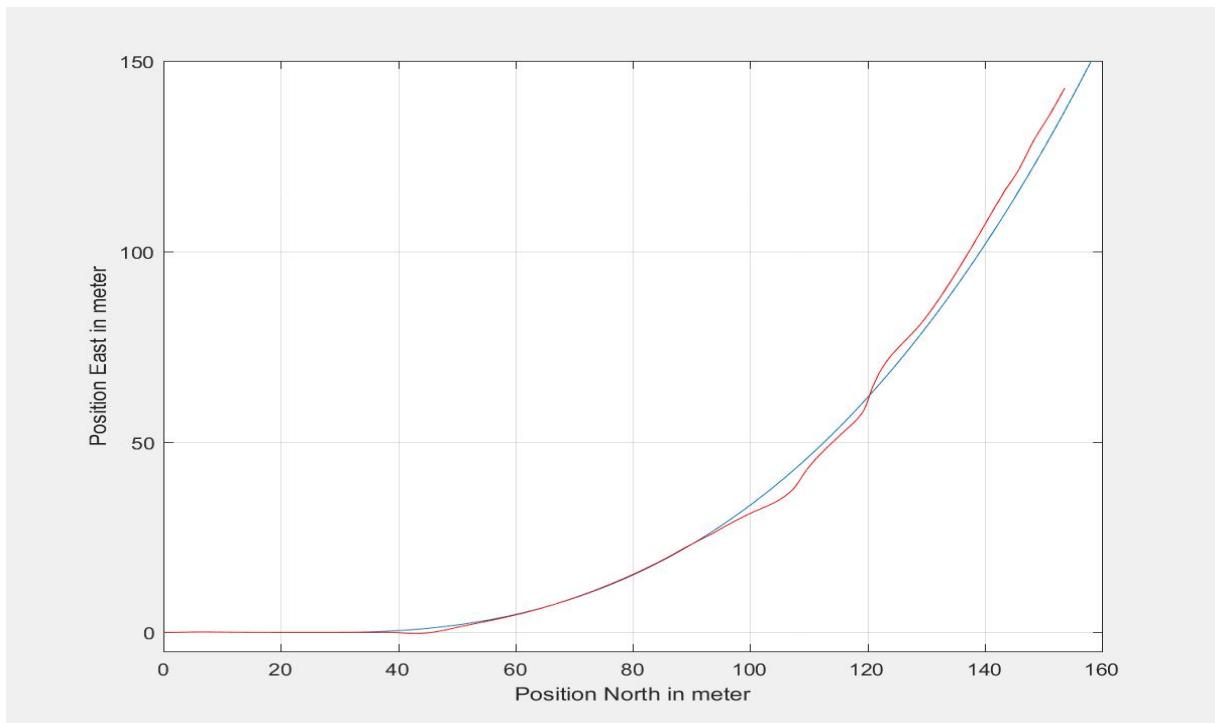


(b) Fehler der AUV Position zur echten Position des Objektes. Am Ende ist zu beobachten, wie sich der systematische Fehler aus c) in einem beständigen Fehler der Fahrt resultiert.

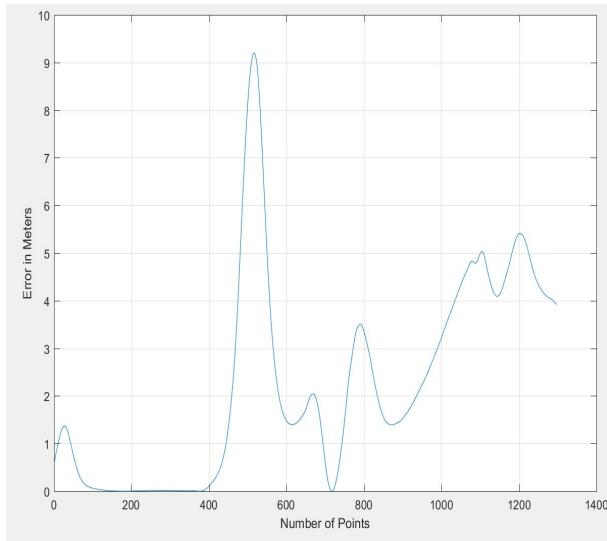


(c) Fehler der detektierten Objektposition zur echten Objektposition. Es scheint, dass die zweite Hälfte der Punkte einen systematischen Fehler hat. Siehe hierfür Kapitel 5.4.

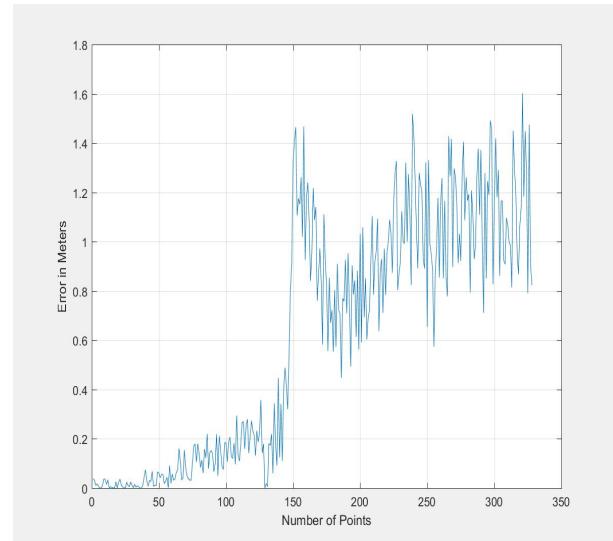
Abbildung 30: Testlauf mit einer Kurve. In a) und b) ist zu erkennen, dass einige Meter benötigt werden, um auf die Kurve zu reagieren. Der zweite größere Fehlerausschlag ist durch eine teilweise komplettete Verdeckung des Objektes zu erklären. In a) ist sehr gut zu beobachten, dass der Fehler zuerst ansteigt, sobald das Objekt nicht sichtbar ist, bei erneuter Detektion des Objektes aber sehr schnell korrigiert wird.



(a) Fahrtverlauf (rot) bei einer Kurve (blau).

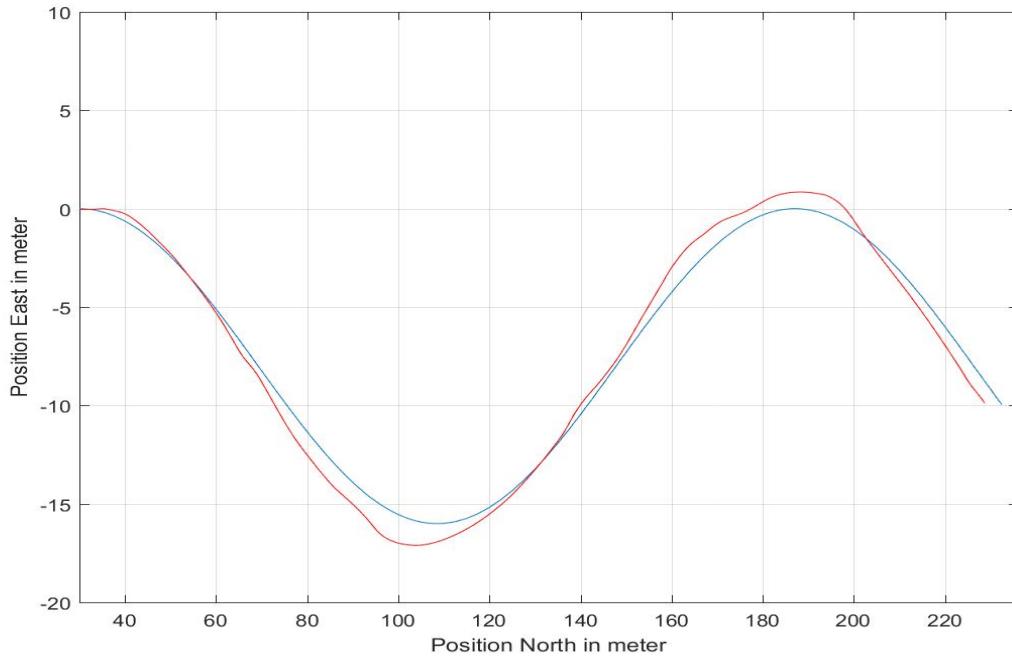


(b) Fehler der AUV Position zur echten Position des Objektes.

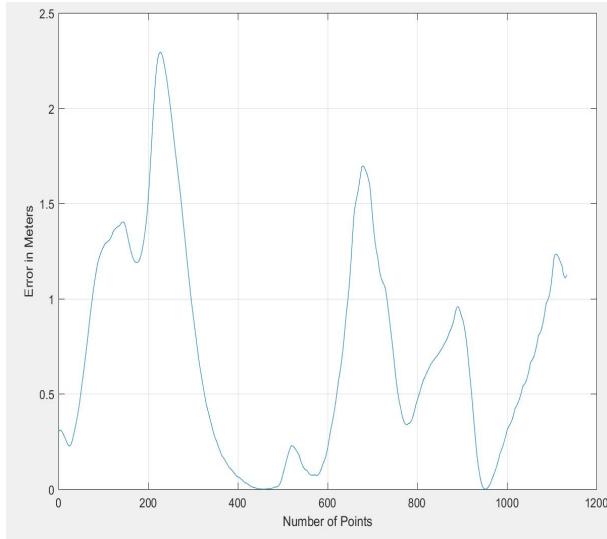


(c) Fehler der detektierten Objektposition zur echten Objektposition.

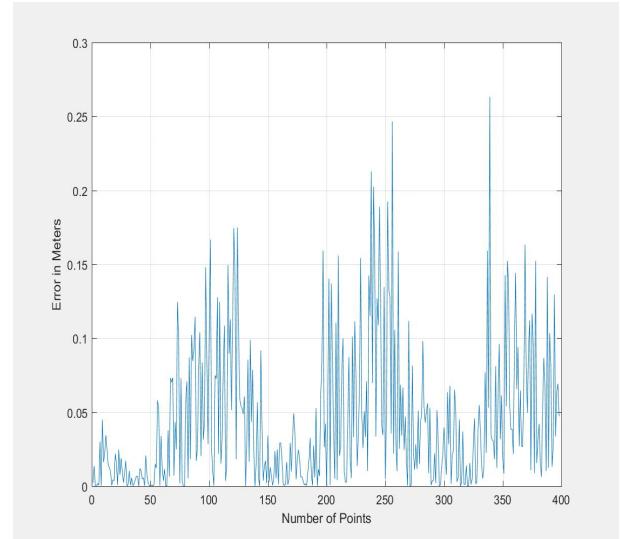
Abbildung 31: Testlauf mit einer Kurve. In diesem Lauf wurde die Kurve in die andere Richtung wie in Abb. 30 erzeugt. Wie zu erwarten sind die Ergebnisse in diesem Lauf analog zur anderen Kurve.



(a) Fahrtverlauf (rot) bei einer Sinuskurve (blau).

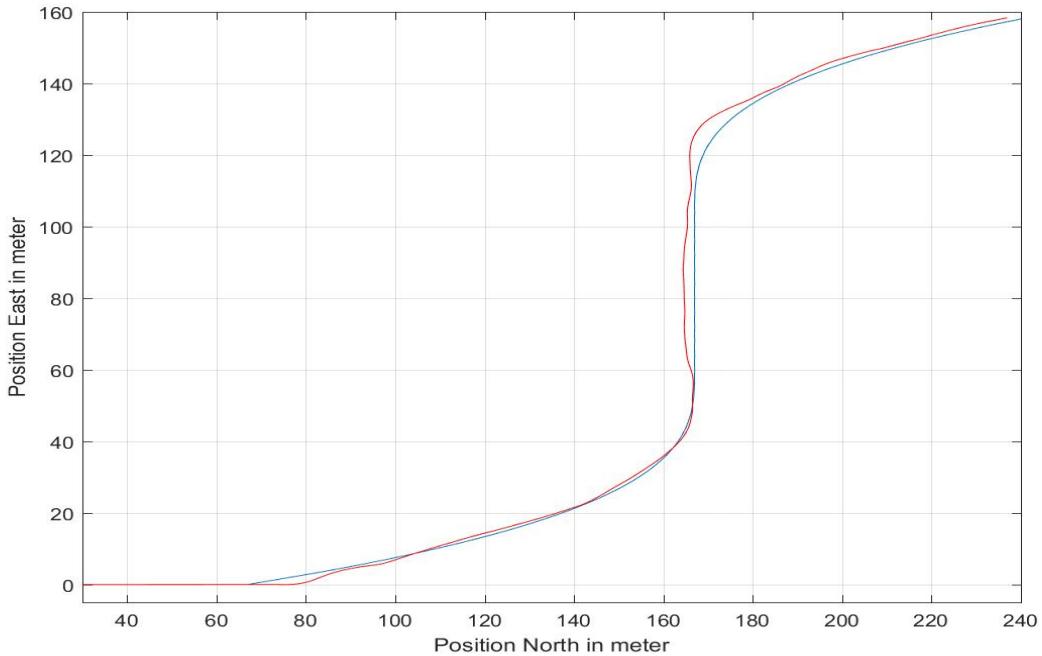


(b) Fehler der AUV Position zur echten Position des Objektes.

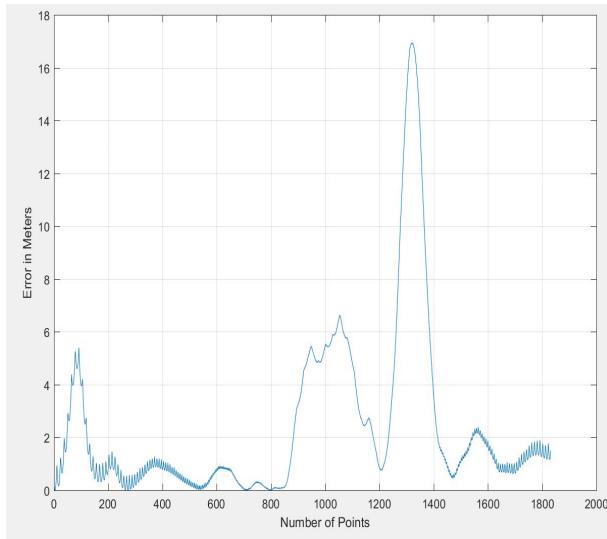


(c) Fehler der detektierten Objektposition zur echten Objektposition.

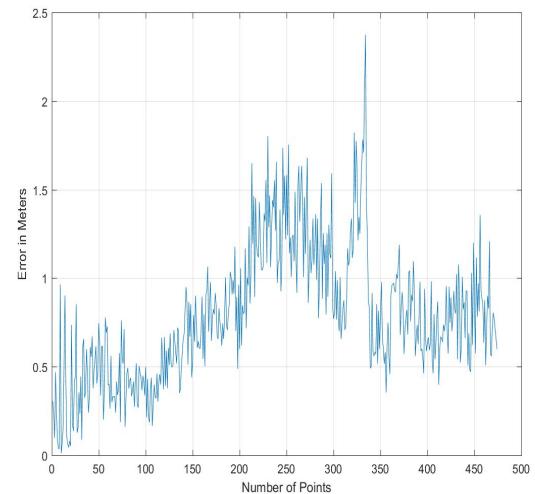
Abbildung 32: Beim Testlauf mit der Sinuskurve ist zu beobachten, dass innerhalb der Kurven aufgrund der Richtungsänderung des Verlaufs einen größeren Fehler der Verfolgung gibt. Nach der Kurve wird dem Objekt jedoch schnell wieder gut gefolgt.



(a) Fahrtverlauf (rot) bei einem kurvigen Objektverlauf(blau). Da die Kurve zu Beginn einen starken Knick macht ist dort ein größerer Fehler, bis richtig reagiert wird.



(b) Fehler der AUV Position zur echten Position des Objektes. Trotz des Fehlers im geraden Bereich und dem sehr großen Fehler innerhalb der Rechtskurve wird das Objekt nach dem Auschlag wieder gut verfolgt.



(c) Fehler der detektierten Objektposition zur echten Objektposition. Der hier zu beobachtete Fehler ist im gesamten Bereich hoch.

Abbildung 33: Die Kurven in diesem Lauf sind für das AUV aufgrund der starken Krümmung schwer zu folgen. Im mittleren Bereich ist auf längerer Strecke ein größerer Fehler. Aufgrund dieses Fehlers wird die Rechtskurve fast *verpasst* jedoch aufgrund des Schätzverfahrens trotzdem noch verfolgt. In diesem Lauf ist der Zusammenhang zwischen Positions- und Detektionsfehler deutlich zu erkennen.

5. Tests und Evaluation

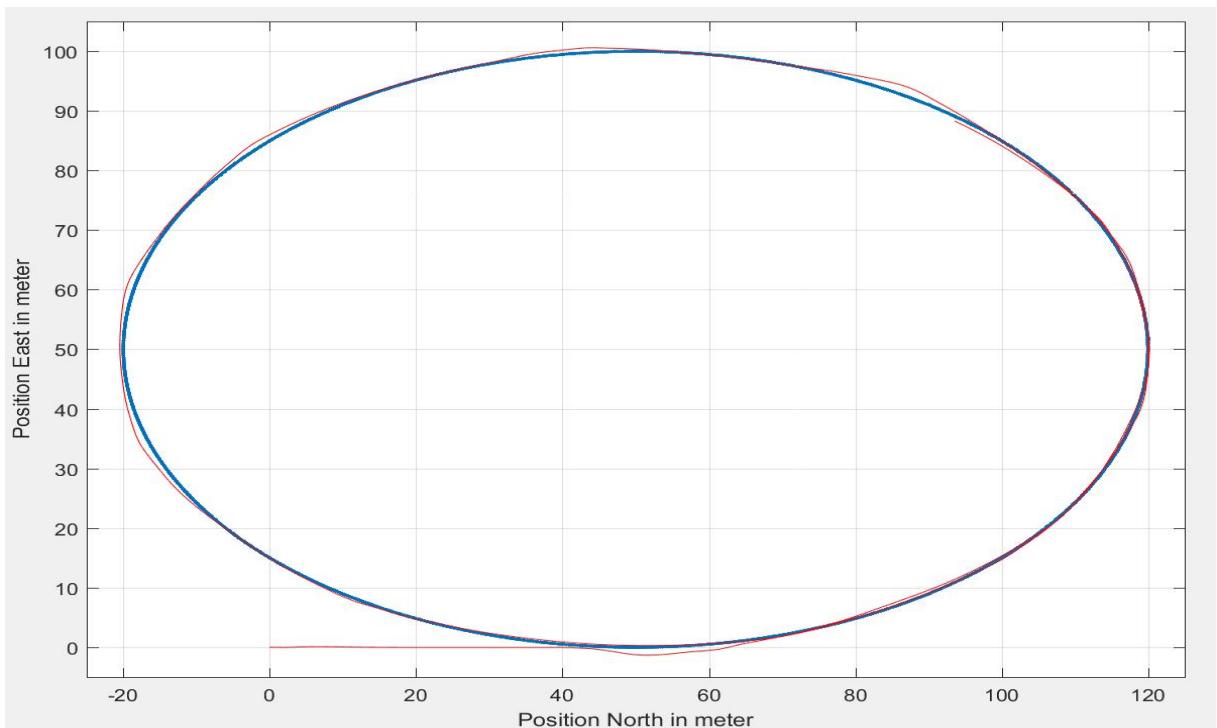
Außerdem wurde noch eine Kurve nach einer langen Geraden erzeugt. Hiermit wird getestet, ob auch wechselnden geometrischen Strukturen gefolgt werden kann.

fehlt
noch

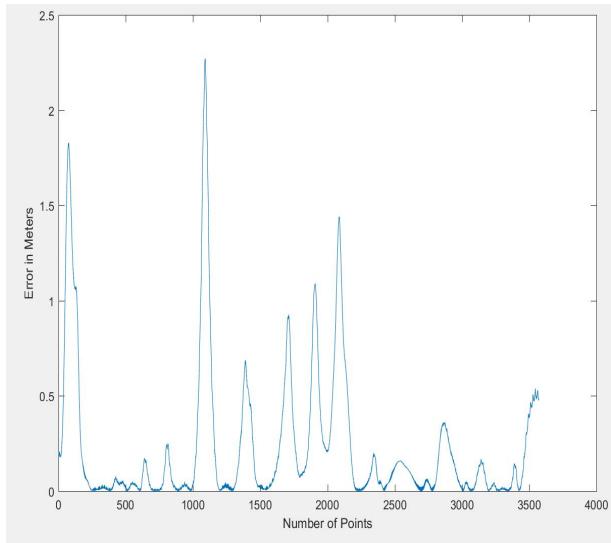
5.2.3. Kreisbahn

Für die finalen Tests wurden Kreisbahnen in Form von Ellipsen verwendet. Eine Ellipse erfüllt einige Eigenschaften, die für die Arbeit nicht trivial zu lösen sind. Zum einen gibt es verschieden stark gebogene Kurven und fast gerade Abschnitte. Zum anderen gibt es ständig Abschnitte, die parallel zur *Y – Achse* verlaufen.

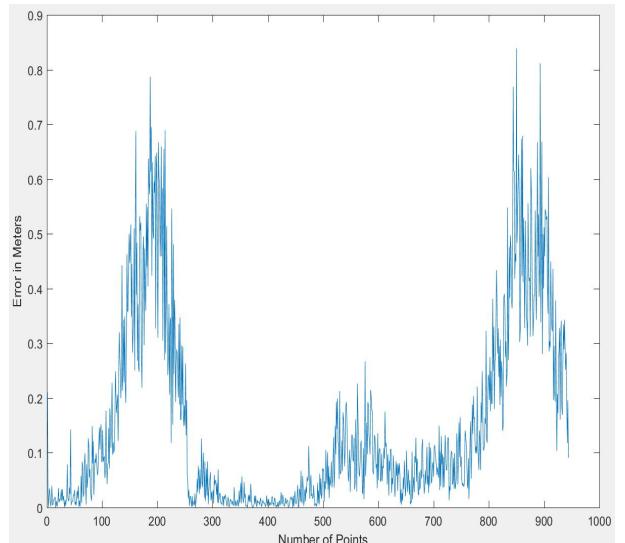
5. Tests und Evaluation



(a) Fahrtverlauf (rot) bei einem Kreis (blau). Es wurden anderthalb runden im Kreis gefahren.

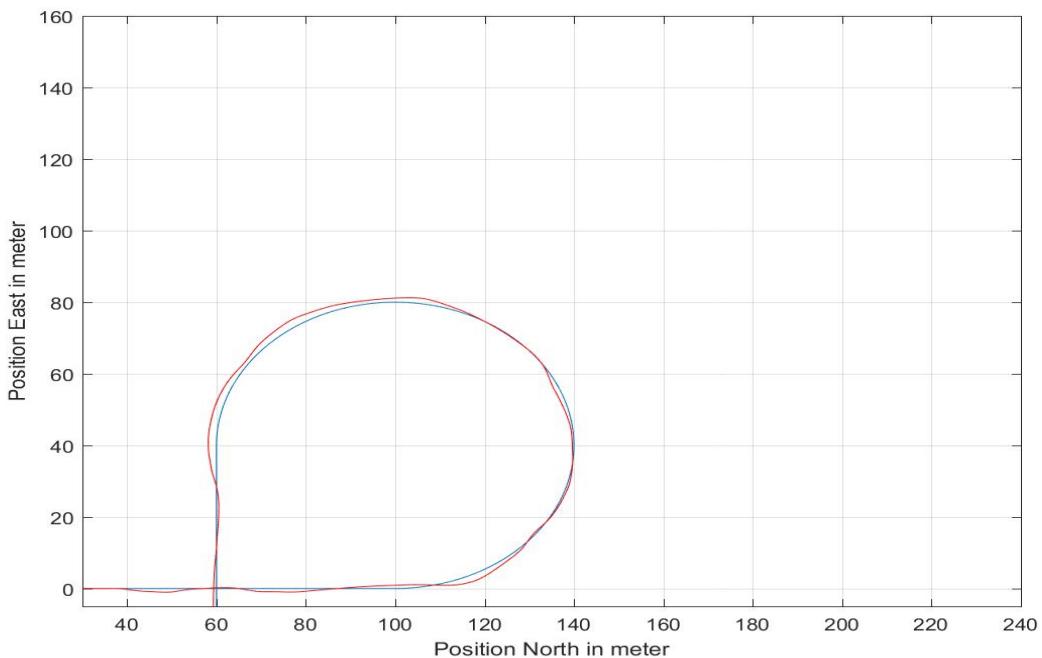


(b) Fehler der AUV Position zur echten Position des Objektes. Es ist ein gleichmäßiges Auftreten von Fehlerspitzen zu beobachten. Der größte Ausschlag ist einer Unsichtbarkeit des Objektes innerhalb des rechten oberen Kreisabschnitts zuzuschreiben.

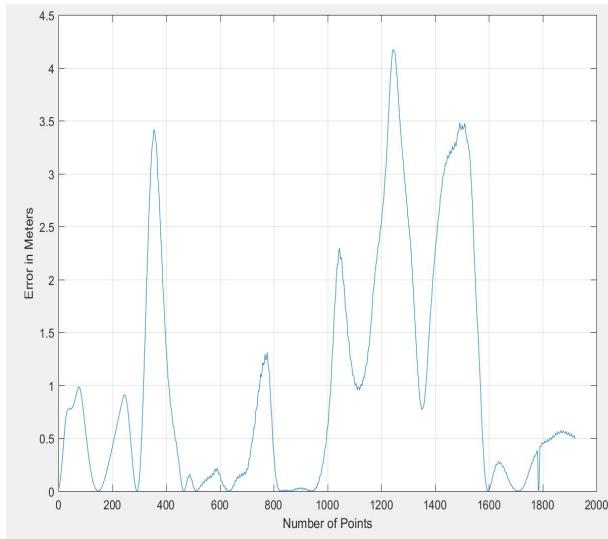


(c) Fehler der detektierten Objektposition zur echten Objektposition. Es sind zwei Bereiche mit größerem Fehler zu beobachten. Diese liegen beide im unteren linken Bereich des Kreises, in dem das Objekt teilweise vom Meeresboden bedeckt ist.

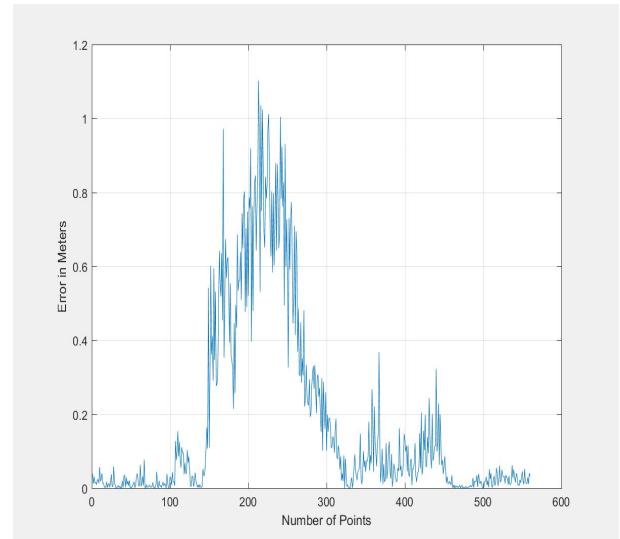
Abbildung 34: Im Testlauf der Kreisbahn ist zu beobachten, wie die ständig ändernde Krümmung der Bahn zu Fehlerspitzen führt. Bei jeder Spalte ist der Fehler der Regression so hoch, dass eine Transformation der detektierten Punkte stattfindet (siehe Kapitel 4.4), die zu einer direkten Abnahme des Fehlers führt.



(a) Fahrtverlauf (rot) bei einer Kreisbahn mit geraden Abschnitten (blau).



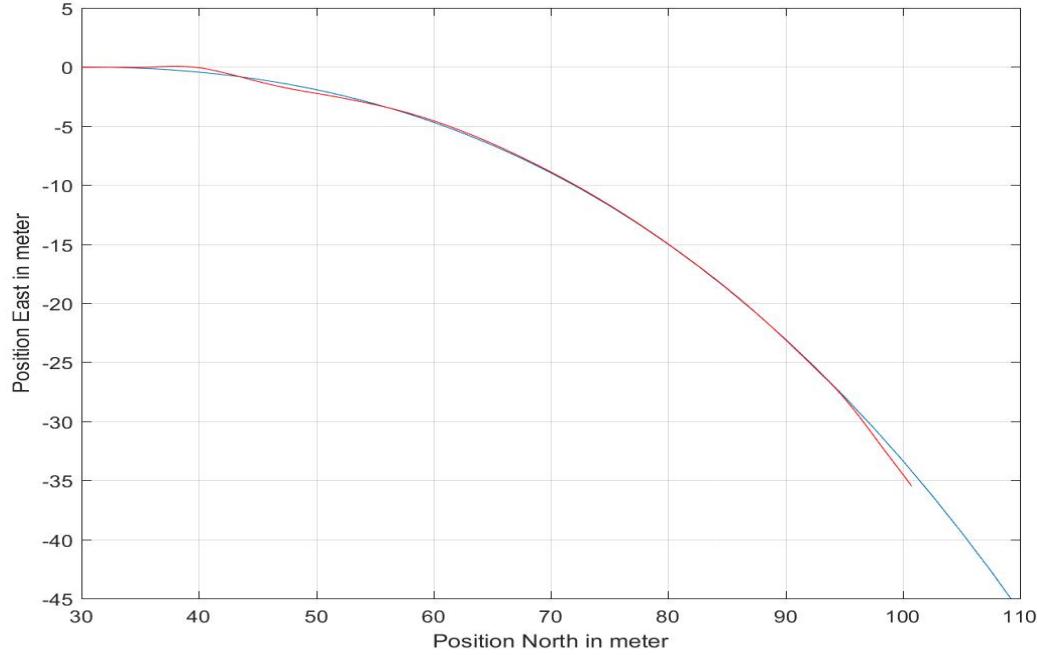
(b) Fehler der AUV Position zur echten Position des Objektes.



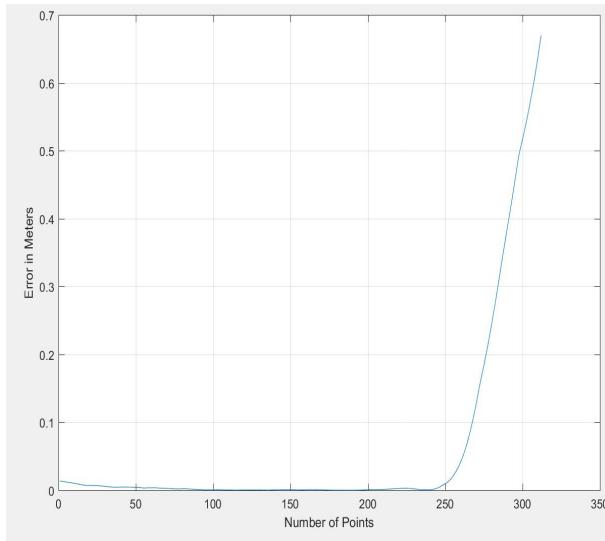
(c) Fehler der detektierten Objektposition zur echten Objektposition.

Abbildung 35: Zu Beginn ist das bereits bekannte einpendeln auf eine gerade Strecke zu beobachten. Beim Übergang in die Kreisbahn ist ein erwarteter hoher Fehler zu beobachten, der durch den Wechsel der Form zu erklären ist. Innerhalb der Kreisbahn sind einige verdeckte Bereiche, was die Fehler in b) und c) erklärt.

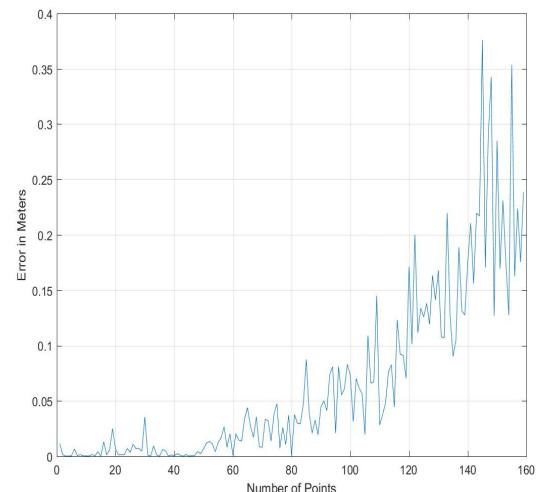
5.2.4. Schlechte Sichtbedingungen



(a) Fahrtverlauf des AUVs (rot) bei einer Kurve (blau) unter schlechten Sichtbedingungen.

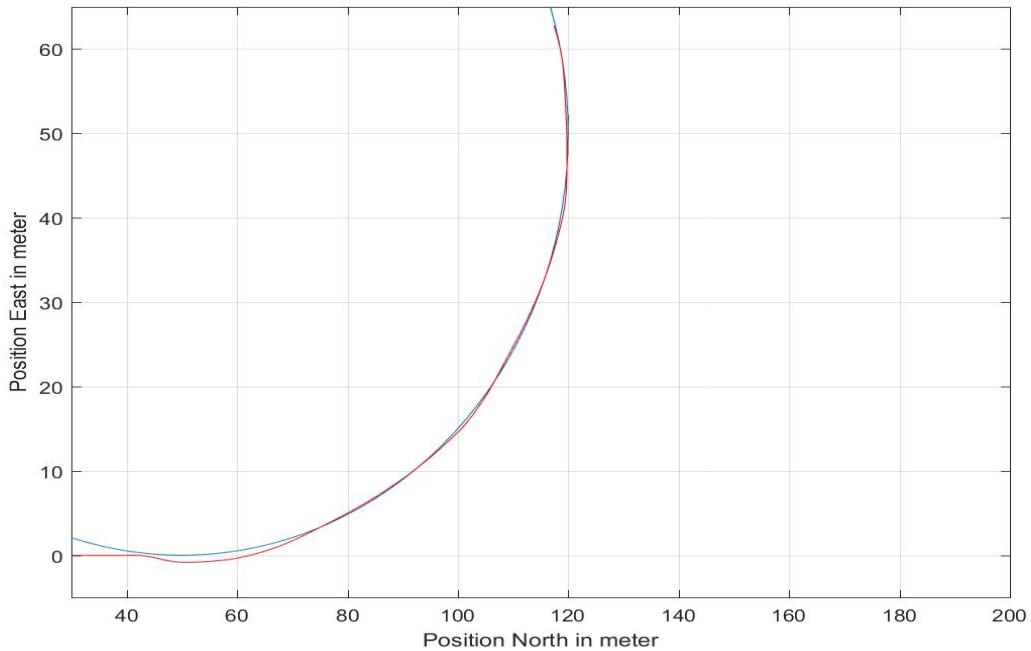


(b) Fehler der AUV Position zur echten Position des Objektes.

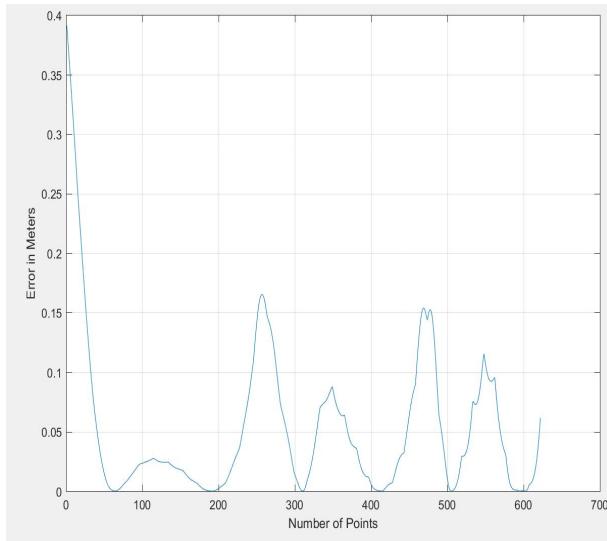


(c) Fehler der detektierten Objektposition zur echten Objektposition. Der Anstieg zum Ende ist auf leichte Verdeckung des Objektes zurückzuführen.

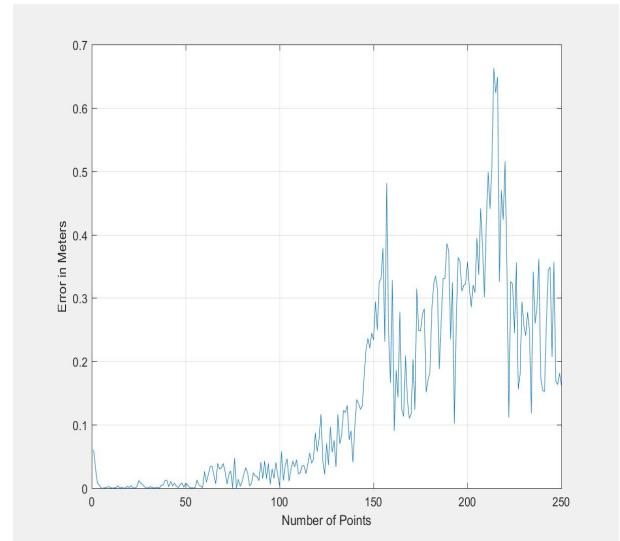
Abbildung 36: Das Folgen der Kurve funktioniert auch bei schlechten Sichtbedingungen. Es ist jedoch zu beobachten, dass eine nur leichte Verdeckung des Objektes einen starken Einfluss auf den Fehler hat.



(a) Fahrtverlauf (rot) bei einer Kreisbahn (blau) unter schlechten Sichtbedingungen.



(b) Fehler der AUV Position zur echten Position des Objektes.



(c) Fehler der detektierten Objektposition zur echten Objektposition.

Abbildung 37: Ähnlich zu Abb. 36 wird dem Objekt gut gefolgt und leichte Verdeckungen haben einen starken Einfluss auf den Fehler.

5.3. Parametrisierung

Während der Tests ist stark aufgefallen, dass das Regressionsverfahren sehr parameterabhängig ist. Wie im vorherigen Kapitel zu sehen ist, liefert die implementierte Lösung mit der richtigen Parametrisierung ein gutes Verhalten. Bei falscher Parametrisierung wird die Verfolgung sehr viel schlechter bis unmöglich.

Große Unterschiede gibt es bei geraden und kurvigen Objekten. Als ausschlaggebende Parameter stellten sich die Gewichtungen der einzelnen Fehlerarten, die starke *Tikhonov Regularisierung* (siehe Gleichung 9) und der maximale Gesamtfehler der Regression bis zu einer Transformation (siehe Abschnitt 4.4) heraus. Bei geraden Objekten führt eine Gleichgewichtung der Fehlerarten, eine starke *Tikhonov Regularisierung* und ein hoher erlaubter Maximalfehler zu sehr guten Ergebnissen (vgl. 5.3.1).

Kurvige Objekte, wie in Abb. 33 oder 35 werden am besten bei einer höheren Gewichtung des Orientierungsfehlers, keine *Tikhonov Regularisierung* und ein geringerer erlaubter Maximalfehler zu guten Ergebnissen. Problematisch ist, dass die *falsche* Parametrisierung (z.B. hoher Maximalfehler für kurvige Objekte) im schlimmsten Fall zu einem großen Fehler, damit einhergehender Sichtverlust zum Objekt und einem schlecht geschätzten Polynom, dass keine erneute Annäherung zum Objekt mehr gelingt.

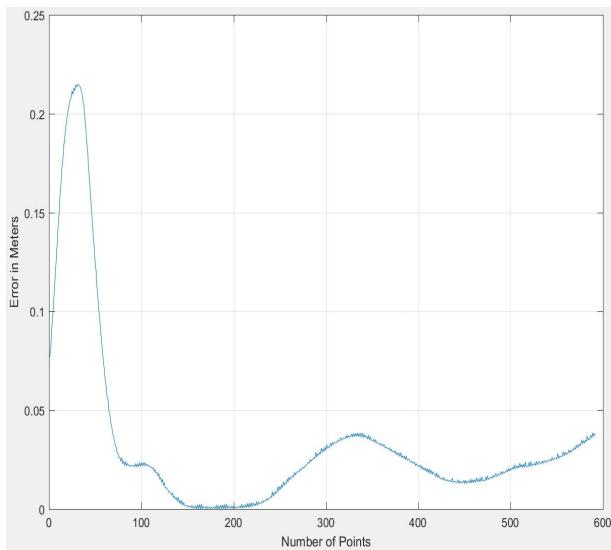
5.3.1. Einpendeln

In jedem Testlauf fiel auf, dass bei erster Sicht des Objektes eine Art **Einpendeln** stattfindet, also ein zuerst großer Fehler, der dann über mehrere Meter beständig abnimmt, bis eine stabile Fahrt über dem Objekt erreicht wird. Diese Beobachtung konnte auch beim Wechsel von geraden Objektverläufen auf kurvige Verläufe gemacht werden.

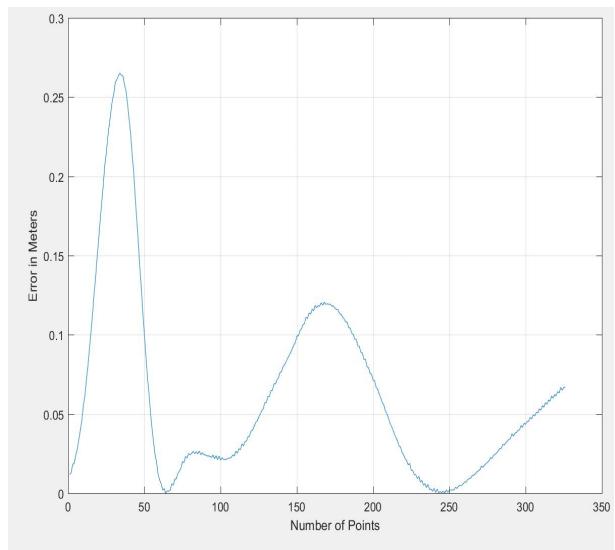
In Abbildung 38 ist diese Beobachtung mit verschiedenen Parametrisierungen dargestellt.

hier
fehlge-
schla-
gene
tests

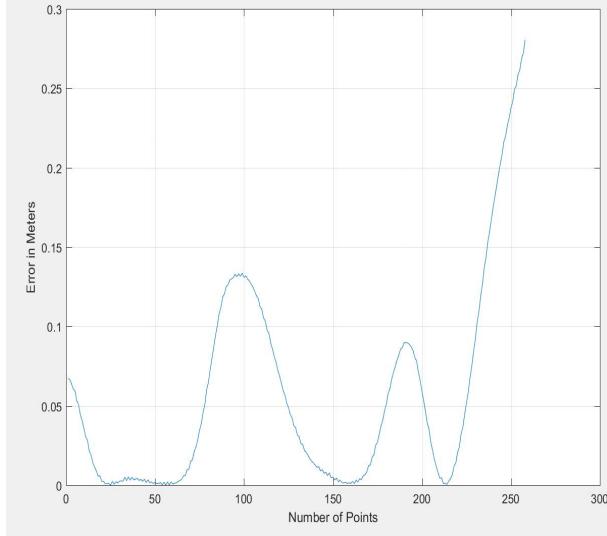
5. Tests und Evaluation



(a) Sehr gute Parametrisierung mit Gleichgewichtung der Fehlerarten, *Tikhonov Regularisierung* und hohem Maximalfehler.



(b) Gute Parametrisierung mit Gleichgewichtung der Fehlerarten, geringer *Tikhonov Regularisierung* und weder hohem, noch geringen Maximalfehler.



(c) Schlechte Parametrisierung mit höherer Gewichtung des Orientierungsfehlers, keiner *Tikhonov Regularisierung* und geringen Maximalfehler.

Abbildung 38: Testlauf mit einem geraden Objekt [Abb. 29] mit unterschiedlicher Parametrisierung. Im Fehler der AUV-Position zur Objektposition ist zu erkennen, dass bei den guten Parametrisierungen der Fehler über die Zeit abfällt. Bei der sehr guten Parametrisierung (a)) sogar noch weitaus schneller. Bei der schlechten Parametrisierung (c)) findet keine Verringerung des Fehlers statt. Die Höhe der Ausschläge nehmen auch nicht beständig ab, wie bei den guten Parametern.

5.4. Systematischer Fehler

Während einiger Testläufe gab es längere Bereiche, in denen stets mit einem leichten Versatz zum Objekt gefahren wurde. Sehr deutlich zu sehen ist dieses Verhalten in den Abbildungen 30, 31 und 33. Betrachtet man bei diesen drei Abbildungen jeweils den Fehler der detektierten Objektposition zur realen Objektposition fällt auf, dass der Fehler um einen bestimmten Wert verteilt ist und einen systematischen Fehler andeutet.

Für das Auftreten dieses Fehlers gibt es einige mögliche Erklärungen. Zum einen fällt auf, dass der systematische Fehler meist nach scharfen Kurven oder teilweiser Unsichtbarkeit des Objektes auftreten. Da die implementierte Lösung bei ausbleibenden Ergebnissen der Objekterkennung die Fahrthöhe erhöht, um den Sichtbereich zu vergrößern und bei erneuter Sichtung wieder auf die Zielhöhe korrigiert, wird nach einem Bereich ohne Detektion stets abwärts gefahren, was zu einem erhöhten Pitch-Wert führt.

Bei scharfen Kurven wird durch die Fahrteigenschaften ein höherer Roll-Wert erreicht, als bei gerade Fahrt. Der systematische Fehler tritt also oft direkt nach Situationen auf, die eine unruhige Fahrt verursachen können. Dies lässt darauf schließen, dass die Transformation von 2D- in 3D-Koordinaten (vgl. 4.2.1) für den Fehler verantwortlich ist.

Eine andere mögliche Erklärung ist darin zu finden, dass das Objekt in den Bereichen mit systematischen Fehler oft leicht verdeckt ist. Verdeckte Objekte führen dazu, dass das Objekt im Binärbild schmäler erscheint. Da die Detektion im Binärbild über eine Box mit der erwarteten Breite des Objektes im Bild durchgeführt wird, führt ein schmäler erscheinendes Objekt zu Problemen. Bei optimal sichtbaren Objekten *passt* diese Box am besten (die meisten Inlier), wenn der Mittelpunkt der Box in horizontaler Richtung genau in der Mitte des Objektes liegt. Bei schmäler erscheinenden Objekten *passt* die Box auch an weiteren Stellen des Objektes genau so gut, wie in der Mitte. Durch den Zufallsaspekt des RANSAC -Algorithmus kann hier ein breiter Bereich als Objektmitte detektiert werden.

Gestützt wird diese Möglichkeit auch durch die Tatsache, dass die Streuung des Fehlers in Bereichen mit systematischen Fehler weitaus größer ist. Eine dritte Möglichkeit ist ein Fehler in der Odometrie des Fahrzeuges. Bei leichten Fehlern in der Positionsschätzung wird durch die Transformation von Body- in Weltkoordinaten dieser Fehler auf die detektierte Objektposition übertragen.

hier
grafik

Max
kann
das
sein?
Kann
man
das ir-
gend-
wie
Prüfen?

5.5. Laufzeittests

auflisten
welche
kompo-
nenten
wieviel
simu-
lati-
onszeit
brau-
chen -
muss
ich
noch
machen

6. Fazit & Ausblick

In diesem Kapitel wird ein Fazit zu den Ergebnissen der Arbeit gezogen. Hierbei wird auch auf die Einsatzfähigkeit der Lösung auf realen Testsystemen eingegangen. Zuletzt wird noch ein Ausblick auf mögliche Volgearbeiten gegeben.

6.1. Fazit

Die in der Arbeit vorgestellte Lösung erzielt, wie die Tests zeigen gute Ergebnisse. Gemäß der Zielsetzung ist es möglich verschiedensten Objektverläufen zuverlässig zu folgen. Wie die Tests zur Objektdetektion zeigen ist die Detektion auch unter schlechten Sichtbedingungen möglich ist. Auch die Verfolgung der Objekte funktioniert dabei zufriedenstellend. Einzig die Störanfällig ist hierbei größer. Es hat sich gezeigt, dass die Fahrzeugregelung bei stetig wechselnden Wegpunkten nicht optimal ist, was in einigen Fällen zu einem schlechten Abfahren des eigentlich guten Polynoms führt. Trotzdem kann das verwendete Verfahren die nicht optimale Polynomverfolgung durch gute Extrapolation in den meisten Fällen ausgleichen. Da der Fokus der Arbeit nicht auf der Fahrzeugregelung liegt und auch kein voller Zugriff darauf besteht, ist der Ausgleich durch die Extrapolation ein gewünschtes Verhalten.

Weniger optimal ist jedoch die Abhängig des Verfahrens an die Parametrisierung. Der erste gut zu wählende Parameter ist der Templateschwellwert für die Objekterkennung. Ist dieser zu gering, ist das Binärbild zu sehr von Störpunkten gefüllt, ist er zu hoch, wird das Objekt nicht mehr gut im Binärbild abgebildet. Beides führt zu einer schlechteren Detektion und somit zu einem schlechteren Gesamtverhalten.

Für die Parametrisierung des Schätzverfahrens wird viel Vorwissen über die Objekte vorausgesetzt. Nur wenn bekannt ist, ob das Objekt stark gekrümmmt ist oder nicht kann eine gute Verfolgung gesichert werden. Bei sich oft ändernden geometrischen Formen der Objekte kann nur sehr schwer eine geeignete Parametrisierung für alle Abschnitte gefunden werden.

Da die naheliegensten Anwendungen liegen in der Untersuchung von menschlich erzeugten Strukturen, wie Ölpipelines oder Unterwasserkabeln. Betrachtet man diese zwei Szenarien ist das benötigte Vorwissen über die Strukturen durchaus gegeben. Bei Pipelines ist alleine durch den Durchmesser kein hoher Krümmungsgrad gegeben. Eine Parametrisierung ist also möglich.

aussagen
zur
Fahrge-
schwin-
digkeit
und
ver-
langsa-
mung
durch

6.2. Ausblick

6.2.1. Parametrisierung

Da die Parametrisierung einen entscheidenden Einfluss auf das Verfahren hat, könnten folgende Arbeiten an dieser Stelle mehr Flexibilität bringen. Zum Beispiel kann ein Verfahren entwickelt werden, dass den Templateschwellwert zur Binärisierung während der Objektdetektion dynamisch anpasst. In einer echten Mission können sich im Verlauf die Sichtbedingungen verändern. Ein fest gesetzter Schwellwert wird in so einem Fall keine Ergebnisse mehr liefern können. Der Schwellwert könnte bei einem über dem gesamten Bild niedrigen Rotwert gesenkt werden, bei vielen Störpunkten kann der Schwellwert erhöht werden oder bei längerem Ausbleiben von Detektionsergebnissen ebenso gesenkt werden.

Ein ähnliches Prinzip kann auch für die Parameter des Schätzverfahrens angewendet werden. Ein Verfahren kann unabhängig von der Regression den aktuellen Verlauf im Bezug auf die Parametrisierung zu schätzen. Dieser Ansatz kann beispielsweise als Klassifizierungsproblem definiert werden und je nach Objektklasse ein definiertes Parameterset genutzt werden.

6.2.2. Regressionsverfahren

In der Implementierten Lösung werden die Daten für die Regression nur Quantitativ gewichtet. Sollte es also viele Fehldetections in einem Bereich geben, in dem das Objekt unsichtbar ist würden diese Fehler das Schätzverfahren stark beeinflussen und die Verfolgung gefährden.

Hier ist eine Qualitative Bewertung der Daten eine gute Lösung. Es kann bewertet werden, wie *sicher* die Objekterkennung eine Detektion als Teil des Objektes erkennt. Eine Grundlage für eine solche Bewertung wird von der implementierten Objekterkennung ausgegeben. In Listing 1 sind die Gütefaktoren angegeben. Die `peakheight` gibt an, wie groß der Unterschied der Rotwert der zum Objekt gehörigen Pixel im Vergleich zum Durchschnitt des gesamten Bildes ist. `Area` bestimmt, wie viel der erwarteten Objektfläche das detektierte Objekt ausfüllt. `relativeCount` gibt das Verhältnis der Inlier nach dem RANSAC zur Gesamtanzahl der Punkte im Binärbild. `fitsBorder` zeigt als Boolean, ob das detektierte Objekt erwarteten Breite passt. `numParts` gibt an in wie vielen Bildsegmenten das Objekt erkannt wurde. `theta` und `phi` geben die Neigungswinkel des AUVs zum Zeitpunkt der Detektion an.

Mit diesen Eigenschaften als Grundlage kann ein *machine learning* Verfahren trainiert werden. Hierfür können Trainingsdaten bestehend aus den Eigenschaften und dem Fehler von jedem Punkt zum echten Objekt. Nach dem Training kann dann aus der Objek-

terkennung ein Fehlerausschlag erwartet und ebenso eine Qualitative Bewertung für die Regression durchgeführt werden.

6.2.3. Integration in Realsystem

Ein weiterer Schritt ist die Integration der Lösung auf dem Realsystem. Hierfür kann die komplette Lösung inklusive Fahrzeugregelung aus Simulink exportiert werden. Dabei ist auch eine Generierung von C/C++-Code möglich, was zu einer Verbesserung der Laufzeit führen kann.

Bevor jedoch die Lösung exportiert werden kann muss das Regressionsverfahren angepasst werden. Da die Regression auf der *Optimization-Toolbox* basiert, welche aber nicht exportiert werden kann, muss hier eine gleichwertige Alternative entweder in MATLAB oder aber auch in Form einer C oder C++ Bibliothek. Ebenfalls kann in diesem Schritt die Regelung angepasst werden, sodass ein allgemein ruhigerer Fahrtverlauf ermöglicht werden kann. Gerade, wenn das AUV als Sensorträger verwendet wird, ist eine ruhige Fahrt fördernd für gute Sensordaten während der Mission.

- ## A. Literaturverzeichnis
- [1] Jan Christian Albiez et al. „CSurvey - An autonomous optical inspection head for AUVs“. In: *Robotics and Autonomous Systems* 67 (2015), S. 72–79.
 - [2] Li Bai, Yan Wang und Michael Fairhurst. „Multiple Condensation filters for road detection and tracking“. In: *Pattern Analysis and Applications* 13.3 (2010), S. 251–262.
 - [3] Illes Balears. „Visual underwater cable/pipeline tracking“. In: (2007).
 - [4] Chris Brunsdon. „Path estimation from GPS tracks“. In: *Proceedings of the 9th International Conference on GeoComputation*. National Centre for Geocomputation, Maynooth University. 2007.
 - [5] Guowei Cai, Ben M Chen und Tong Heng Lee. *Unmanned rotorcraft systems*. Springer Science & Business Media, 2011.
 - [6] Qiang Chen und Hong Wang. „A real-time lane detection algorithm based on a hyperbola-pair model“. In: *2006 IEEE Intelligent Vehicles Symposium*. IEEE. 2006, S. 510–515.
 - [7] M Dabrowska. „Avalon by DFKI RIC and University of Bremen“. In: (2011).
 - [8] Gian Luca Foresti und Stefania Gentili. „A vision based system for object detection in underwater images“. In: *International Journal of Pattern Recognition and Artificial Intelligence* 14.02 (2000), S. 167–188.
 - [9] JO Hallset. „Simple vision tracking of pipelines for an autonomous underwater vehicle“. In: *Robotics and Automation, 1991. Proceedings., 1991 IEEE International Conference on*. IEEE. 1991, S. 2767–2772.
 - [10] Jari Kaipio und Erkki Somersalo. *Statistical and computational inverse problems*. Bd. 160. Springer Science & Business Media, 2006.
 - [11] Joel C McCall und Mohan M Trivedi. „An integrated, robust approach to lane marking detection and lane tracking“. In: *Intelligent Vehicles Symposium, 2004 IEEE*. IEEE. 2004, S. 533–537.
 - [12] Jong Woung Park, Joon Woong Lee und Kyung Young Jhang. „A lane-curve detection based on an {LCF}“. In: *Pattern Recognition Letters* 24.14 (2003), S. 2301–2313. ISSN: 0167-8655. DOI: [http://dx.doi.org/10.1016/S0167-8655\(03\)00056-4](http://dx.doi.org/10.1016/S0167-8655(03)00056-4). URL: <http://www.sciencedirect.com/science/article/pii/S0167865503000564>.
 - [13] Christopher Rasmussen. „Texture-Based Vanishing Point Voting for Road Shape Estimation.“ In: *BMVC*. Citeseer. 2004, S. 1–10.

- [14] Sivakumar Rathinam et al. „Autonomous searching and tracking of a river using an UAV“. In: *2007 American Control Conference*. IEEE. 2007, S. 359–364.
- [15] Dan Simon. *Optimal state estimation: Kalman, H infinity, and nonlinear approaches*. John Wiley & Sons, 2006.
- [16] Bahare Torkaman und Mohammad Farrokhi. „Real-time visual tracking of a moving object using pan and tilt platform: A Kalman filter approach“. In: *20th Iranian Conference on Electrical Engineering (ICEE2012)*. IEEE. 2012, S. 928–933.
- [17] Vincent Voisin et al. „Road Markings Detection and Tracking Using Hough Transform and Kalman Filter“. In: *Advanced Concepts for Intelligent Vision Systems: 7th International Conference, ACIVS 2005, Antwerp, Belgium, September 20-23, 2005. Proceedings*. Hrsg. von Jacques Blanc-Talon et al. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005, S. 76–83. ISBN: 978-3-540-32046-3. DOI: [10.1007/11558484_10](https://doi.org/10.1007/11558484_10). URL: http://dx.doi.org/10.1007/11558484_10.
- [18] Yue Wang, Eam Khwang Teoh und Dinggang Shen. „Lane detection and tracking using B-Snake“. In: *Image and Vision computing* 22.4 (2004), S. 269–280.

1.	Screenshot der Simulationsumgebung	3
2.	Das Bildkoordinatensystem	5
3.	Das Kamerakoordinatensystem	5
4.	Das Body-Koordinatensystem	6
5.	Die Neigungswinkel im Body-Koordinatensystem	6
6.	MATLAB und VRML Koordinatensystem	7
7.	Typischer Straßenverlauf mit entsprechendem Kantenbild	8
8.	Detektion eines Straßenverlaufs über eine LCF	9
9.	Detektion eines Straßenverlaufs mit dem RANSAC -Algorithmus	10
10.	Detektion eines Straßenverlaufs mit der <i>Hough Transformation</i>	11
11.	Template zur Pipelinedetektion aus <i>CSurvey</i>	12
12.	Detektion einer Pipeline im Kantenbild	13
13.	Pipelinedetektion mit neuronalem Netzwerk.	14
14.	Schätzung einer Objektbewegung mit Kalman-Filter.	15
15.	Abbildung eines Pfadverlaufs auf Basis von GPS-Daten.	16
16.	Abbildung eines Flusses mit Regression	17
17.	Verfahren zur Bestimmung der Wegpunkte	20
18.	Simulationsbilder	21
19.	Template zum Bestimmen des Binärbilds	27
20.	Helligkeit und Rotwert im echten Testbild	28
21.	Helligkeit und Rotwert im Simulationsbild	29
22.	Falsch detektierte Bestimmung der Objektorientierung aufgrund der Beschränkung der Ausrichtungen für den RANSAC	31
23.	Ein gerades Objekt, dass ohne Einschränkungen zu sehen ist wird unter verschiedenen Sichtbedingungen und Bildqualität getestet.	36
24.	37
25.	38
26.	39
27.	Tests der Objekterkennung auf realen Bilder aufgenommen im Unisee vom AUV <i>DAGON</i> . Trotz sehr schlechten Sichtbedingungen und vielen Störpunkten im Binärbild wird die Pipeline in den oberen zwei Segmenten gut erkannt. In <i>d)</i> ist im unteren Bereich eine Fehldetektion aufgrund der hohen Störpunkttdichte in diesem Bereich. Die Randbereiche werden während des Binärisierungsprozess am Bild hinzugefügt, um dass Template auch auf den ersten und letzten Pixeln anwenden zu können. Diese Bereiche werden bei der Detektion nicht betrachtet.	40

28. Test der Objekterkennung auf einem realen Bild aufgenommen im Unisee vom AUV <i>DAGON</i> . Die Pipeline reflektiert sehr stark und hebt sich dadurch deutlich vom Hintergrund ab. Jedoch gibt es eine starke Reflexion des Wassers nah an der Pipeline, was zu einer Fehldetektion im zweiten Segment führt.	41
29. Testlauf an einem geraden Objekt. Nach anfänglich größeren Fehler folgt das AUV dem Objekt mit nur sehr geringem Fehler. Das Einpendeln ist auf die Berechnung des Polynoms zurückzuführen, da bei wenigen Punkten zu Beginn der Verlauf noch nicht eindeutig als Gerade bestimmbar ist. Siehe hierfür Kapitel 5.3.1	43
30. Testlauf mit einer Kurve. In <i>a)</i> und <i>b)</i> ist zu erkennen, dass einige Meter benötigt werden, um auf die Kurve zu reagieren. Der zweite größere Fehlerausschlag ist durch eine teilweise komplett Verdeckung des Objektes zu erklären. In <i>a)</i> ist sehr gut zu beobachten, dass der Fehler zuerst ansteigt, sobald das Objekt nicht sichtbar ist, bei erneuter Detektion des Objektes aber sehr schnell korrigiert wird.	45
31. Testlauf mit einer Kurve. In diesem Lauf wurde die Kurve in die andere Richtung wie in Abb. 30 erzeugt. Wie zu erwarten sind die Ergebnisse in diesem Lauf analog zur anderen Kurve.	46
32. Beim Testlauf mit der Sinuskurve ist zu beobachten, dass innerhalb der Kurven aufgrund der Richtungsänderung des Verlaufs einen größeren Fehler der Verfolgung gibt. Nach der Kurve wird dem Objekt jedoch schnell wieder gut gefolgt.	47
33. Die Kurven in diesem Lauf sind für das AUV aufgrund der starken Krümmung schwer zu folgen. Im mittleren Bereich ist auf längerer Strecke ein größerer Fehler. Aufgrund dieses Fehlers wird die Rechtskurve fast <i>verpasst</i> jedoch aufgrund des Schätzverfahrens trotzdem noch verfolgt. In diesem Lauf ist der Zusammenhang zwischen Positions- und Detektionsfehler deutlich zu erkennen.	48
34. Im Testlauf der Kreisbahn ist zu beobachten, wie die ständig ändernde Krümmung der Bahn zu Fehlerspitzen führt. Bei jeder Spitze ist der Fehler der Regression so hoch, dass eine Transformation der detektierten Punkte stattfindet (siehe Kapitel 4.4), die zu einer direkten Abnahme des Fehlers führt.	50

35.	Zu Beginn ist das bereits bekannte einpendeln auf eine gerade Strecke zu beobachten. Beim Übergang in die Kreisbahn ist ein erwarteter hoher Fehler zu beobachten, der durch den Wechsel der Form zu erklären ist. Innerhalb der Kreisbahn sind einige verdeckte Bereiche, was die Fehler in <i>b)</i> und <i>c)</i> erklärt.	51
36.	Das Folgen der Kurve funktioniert auch bei schlechten Sichtbedingungen. Es ist jedoch zu beobachten, dass eine nur leichte Verdeckung des Objektes einen starken Einfluss auf den Fehler hat.	52
37.	Ähnlich zu Abb. 36 wird dem Objekt gut gefolgt und leichte Verdeckungen haben einen starken Einfluss auf den Fehler.	53
38.	Testlauf mit einem geraden Objekt [Abb. 29] mit unterschiedlicher Parametrisierung. Im Fehler der AUV-Position zur Objektposition ist zu erkennen, dass bei den guten Parametrisierungen der Fehler über die Zeit abfällt. Bei der sehr guten Parametrisierung (<i>a)</i>) sogar noch weitaus schneller. Bei der schlechten Parametrisierung (<i>c)</i>) findet keine Verringerung des Fehlers statt. Die Höhe der Ausschläge nehmen auch nicht beständig ab, wie bei den guten Parametern.	55
39.	68
40.	68
41.	69
42.	69
43.	70
44.	70
45.	71
46.	71
47.	72
48.	73
49.	73

1.	Kreisgleichung zum Test ob ein Punkt auf einem Kreis liegt.	19
2.	Transformation der Kamerakoordinaten zu Bodykoordinaten	24
3.	Transformation der Bodykoordinaten zu Weltkoordinaten	24
4.	Transformation von Weltkoordinaten in VRML Koordinaten	25
5.	Templatewertberechnung für ein Pixel als Formelausdruck	27
6.	Least Squares Ansatz	32
7.	Weighted Least Squares Verfahren	32
8.	Funktion zum überprüfen, ob die Steigung einen Maximalwert nicht übersteigt.	33
9.	Zusammensetzung der Funktion F, die minimiert wird.	33

1.	Initialisierung der <i>pointInFrame</i> Struktur die erkannte Punkte in verschiedenen Referenzkoordinatensystemen abbildet.	18
2.	Enumeration der Frames	22
3.	Transformation von <i>source</i> in <i>target</i> Frame	22
4.	Eingesetzter RANSAC als Pseudocode	30
5.	Pseudocode des Schätzverfahrens	34

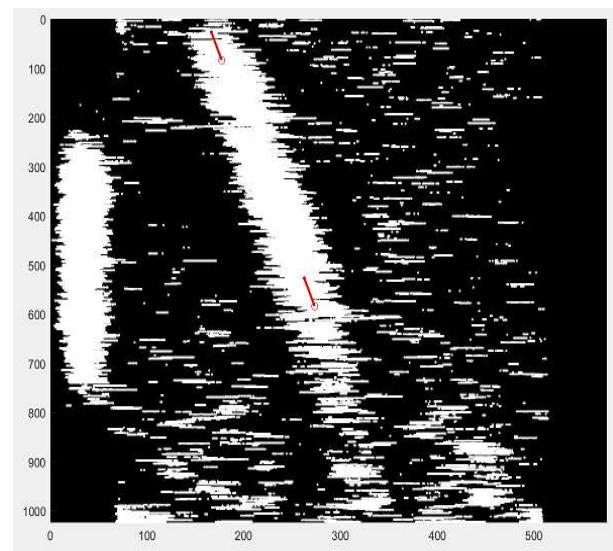
E. Anhang

E.1. Objekterkennung weitere Tests

Im folgenden folgt eine Übersicht Objekterkennung auf verschiedenen Testbildern aus dem Unisee. Die Objekterkennung arbeitet natürlich wie in der Arbeit beschrieben. Die Kennzeichnung Original- und im Binärbild dienen nur der verschiedenen Darstellung.



(a) Originalbild

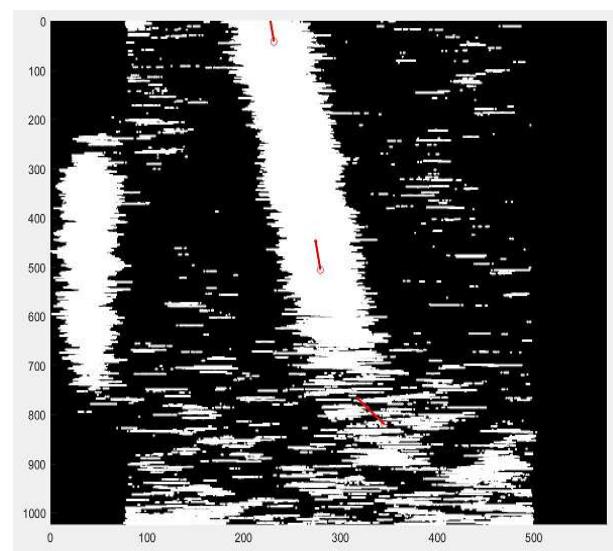


(b) Erkannte Objekte

Abbildung 39



(a) Originalbild

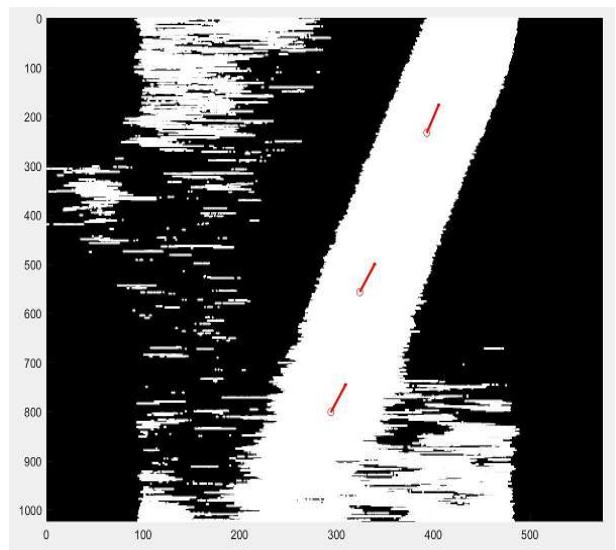


(b) Erkannte Objekte

Abbildung 40



(a) Originalbild

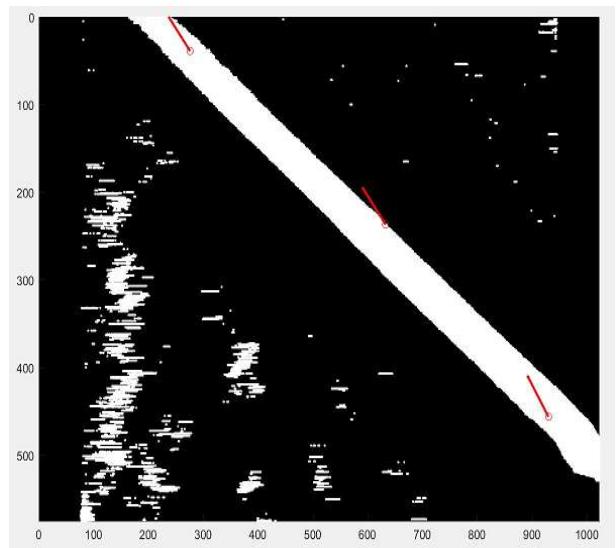


(b) Erkannte Objekte

Abbildung 41



(a) Originalbild

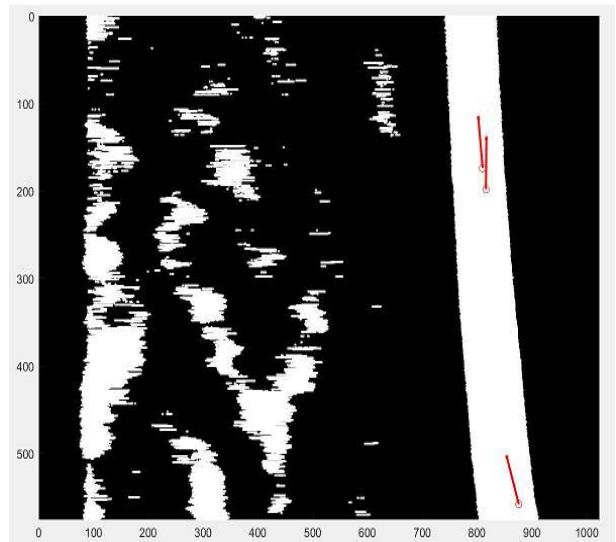


(b) Erkannte Objekte

Abbildung 42



(a) Originalbild

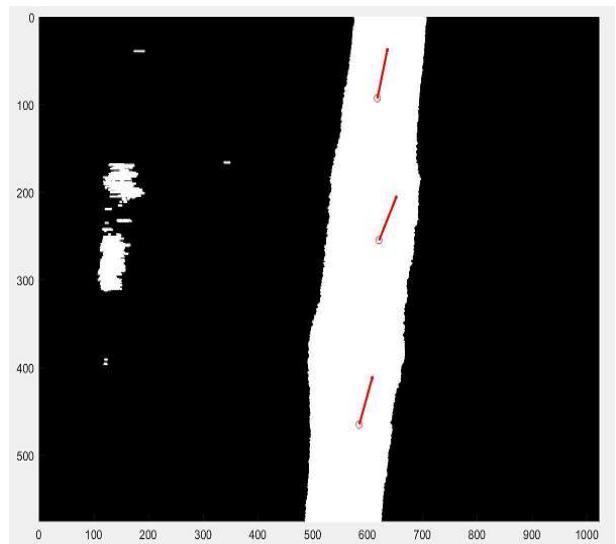


(b) Erkannte Objekte

Abbildung 43



(a) Originalbild

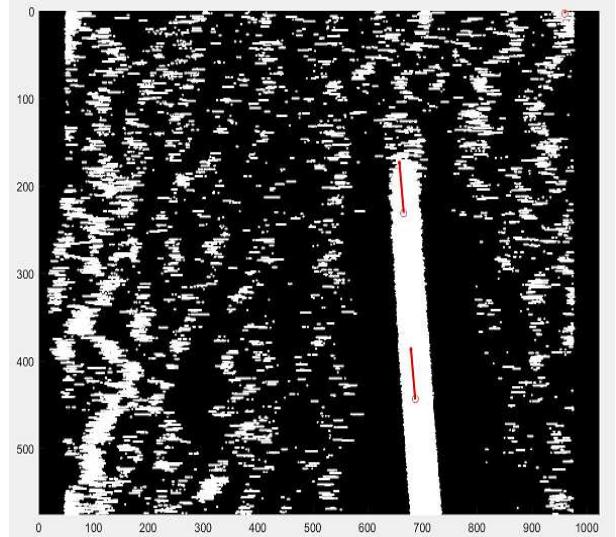


(b) Erkannte Objekte

Abbildung 44

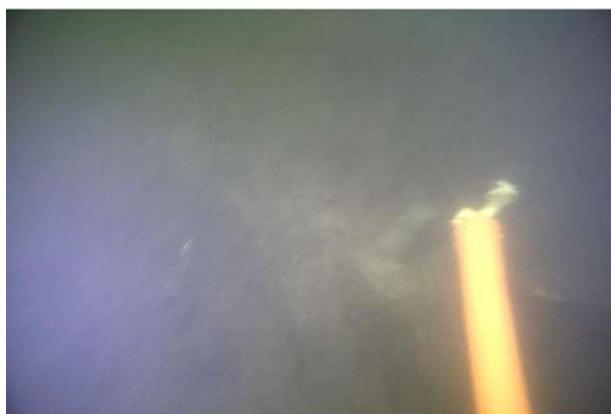


(a) Originalbild



(b) Erkannte Objekte

Abbildung 45



(a) Originalbild

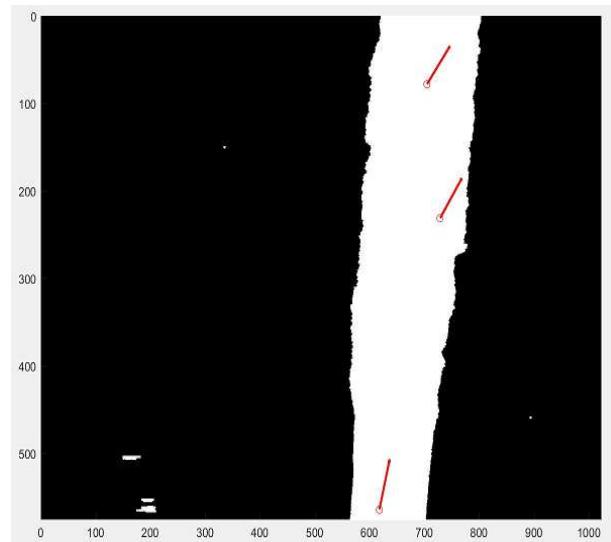


(b) Erkannte Objekte

Abbildung 46



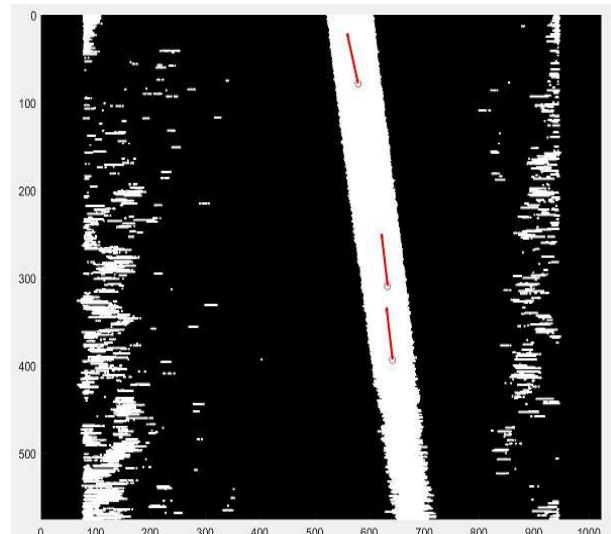
(a) Originalbild



(b) Erkannte Objekte



(c) Originalbild

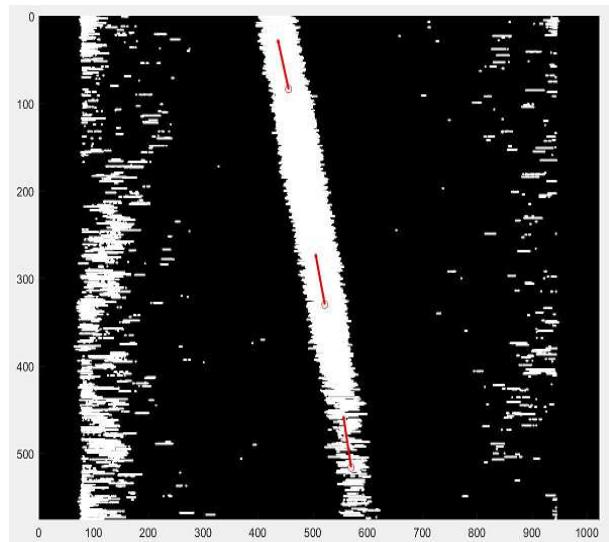


(d) Erkannte Objekte

Abbildung 47



(a) Originalbild

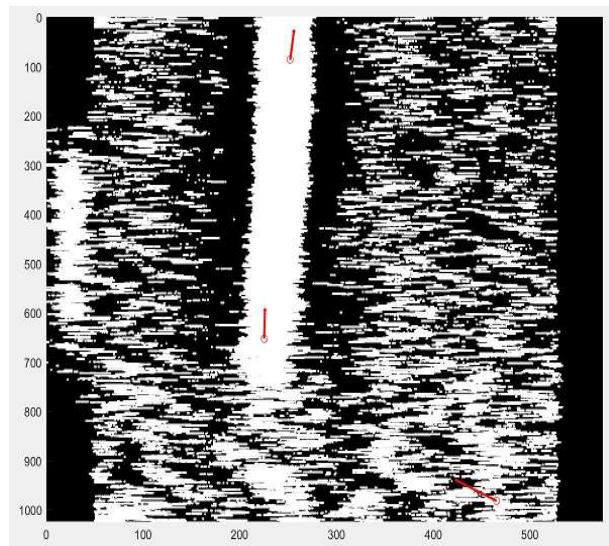


(b) Erkannte Objekte

Abbildung 48



(a) Originalbild



(b) Erkannte Objekte

Abbildung 49